

ACA 1

Presentado por:

Francy Nallerly Santiago Franco

Luis Carlos Jurado Ortega

Michell Dayana Carrillo López

Julián Andrés Mancera García

Corporación Unificada Nacional de Educación Superior

Especialización en Analítica de datos

APLICACIÓN DE INTELIGENCIA DE NEGOCIOS

PRESENTADO A:

Andrés Mauricio Valderrama Giraldo

01 de noviembre de 2026

Contenido

Introducción 4

Objetivo 5

Objetivo general 5

Objetivos específicos 5

Diseño del análisis 5

Auditoría de calidad de los datos 6

Balance de clases y perfil de los registros 7

Hallazgos verificables en el Excel original 8

Análisis exploratorio de los datos 8

Correlación y preparación del modelo 11

Partición y escalamiento 11

Capacidad de discriminación 13

Conclusiones 15

Referencias Bibliográficas 16

Anexos 17

Lista de tablas

Tabla 1: Variables utilizadas en la clasificación de afección coronaria 6
Tabla 2:Reglas operativas de integridad de las variables 7
Tabla 3:Balance de target antes y después de la depuración 7
Tabla 4:Medias por clase reportadas en el notebook 9
Tabla 5:Métrica de la clase positiva y desempeño global 13

Lista de Ilustraciones

Ilustración 1:Balance de la variable objetivo 9
Ilustración 2: Distribución de Thalach según la clase 10
Ilustración 3: Matriz de correlación de las variables continuas y target 11
Ilustración 4: Matriz de confusión en el conjunto de prueba 12
Ilustración 5: Curva ROC de la regresión logística 13

Introducción

La clasificación de afección coronario plante una pregunta concreta: ¿qué tan bien permiten las características registradas distinguir los casos con presencia de afección de aquellos sin ella? Para responder la pregunta, en análisis examina la calidad de los datos, identifica patrones entre las variables y evalúa modelos capaces de combinar esas señales en una predicción. Desde la inteligencia de negocios, este proceso permite convertir los registros en información útil para apoyar decisiones y reconocer sus posibles errores.

El caso de estudio estables que target = 1 representa presencia de afección y el target = 0, ausencia. La evaluación da prioridad a la sensibilidad, es decir, a la capacidad de detectar los positivos reales, debido a la importancia de reducir las omisiones. A la vez, considera las falsas alertas que produce cada modelo. Como los datos no incluyen seguimiento temporal, las predicciones describen la clasificación de los registros disponibles y no demuestran riesgo de un evento futuro.

Objetivo

Objetivo general

Analizar los resultados de la regresión logística implementada en el notebook, contrastar su contexto con el archivo df_final.xlsx e interpretar su desempeño para la clasificación de target, con atención a la sensibilidad y a los límites de la evidencia disponible.

Objetivos específicos

Describir el balance de clases, las medias por grupo y las asociaciones exploratorias mostradas en el notebook.

Explicar la partición estatificada, el escalamiento y la configuración del modelo que efectivamente ejecuta el código.

Interpretar la matriz de confusión, la exactitud, la sensibilidad, la precisión, F1 y ROC-AUC.

Identificar las diferencias entre el Excel entregado y la base limpia utilizado.

Diseño del análisis

El estudio utiliza la base df_final compuesta por 320 registros y 29 columnas; la variable de respuesta es target; las otras 28 columnas reúnen cinco mediciones continuas y 23 indicadores que representan categorías. Cada fina constituye una observación del análisis. La base no incluye un identificador que permita establecer si todas las filas corresponden a personas distintas.

Tabla 1: Variables utilizadas en la clasificación de afección coronaria

Variable	Descripción	Tipo
age	Edad registrada	
trestbps	Presión arterial en reposo	Continua
chol	Colesterol	Continua
thalach	Frecuencia cardíaca máxima	Continua
oldpeak	Depresión del segmento ST	Continua
Indicadoras	23 columnas agrupadas en ocho atributos	Continua
target	Presencia o ausencia de afección	Binarias

El desarrollo comienza con la revisión de valores inválidos y la descripción de los grupos. Después se separan los registros de entrenamiento y prueba, se preparan las variables y se comparan regresión logística, bosque aleatorio y SVM. La selección del modelo y de su umbral se realiza con entrenamiento; el conjunto reservado permite evaluar la decisión final sobre registros que no participaron en el ajuste.

Auditoría de calidad de los datos

El Excel contiene 320 filas y 29 columnas: target y 28 predictores. Estos incluyen cinco variables continuas y 23 indicadoras binarias distribuidas en ocho atributos. No hay celdas vacías, pero sí contenido inválido. Una celda llena puede contener una fecha donde debería existir una medición o una cifra cuya magnitud impide interpretarla.

Tabla 2:Reglas operativas de integridad de las variables

Variable	Intervalo aceptado	Tratamiento fuera del intervalo
age	1 a 120	Excluir registro
trestbps	1 a 350	Excluir registro
chol	1 a 1500	Excluir registro
thalach	1 a 300	Excluir registro
oldpeak	−10 a 20	Marcar como faltante

Se identifican 31 filas con magnitudes del orden de 10^{15} a 10^{16} en presión, colesterol o frecuencia cardíaca máxima. Corresponden a las filas 291 a 321 del Excel, contando el encabezado, y todas pertenecen a target = 0. El control también comprueba que las indicadoras sean binarias y que cada grupo sume uno. Se excluyen 31 filas en total, equivalentes al 9,69 % de la base.

En oldpeak aparecen 105 fechas en el archivo original. No se convierten en decimales a partir del día o el mes, porque eso supondría recuperar un valor desconocido. Tras la depuración quedan 103 faltantes, que se conservan para imputación posterior. La base analítica resultante contiene 289 registros y no presenta duplicados exactos.

Balance de clases y perfil de los registros

Tabla 3:Balance de target antes y después de la depuración

Clase	Original n	Original %	Depurado n	Depurado %
0 Ausencia	160	50,00	129	44,64
1 Presencia	160	50,00	160	55,36
Total	320	100,00	289	100,00

La relación entre positivos y negativos pasa de 1 a 1 a aproximadamente 1,24 a 1. Esta diferencia no representa un desbalance fuerte, por lo que se conserva la distribución observada sin aplicar sobremuestreo. Aun así, la exactitud no basta para evaluar la detección de positivos. Además, la exclusión afecta solo a negativos y puede modificar el perfil del grupo que queda disponible para aprender

Hallazgos verificables en el Excel original

Se identifican 31 filas con magnitudes del orden de 10^{15} a 10^{16} en trestbps, chol o thalach. Todas pertenecen a target = 0 y corresponden a las filas 291 a 321 de Excel, contando el encabezado. También hay 105 celdas de oldpeak almacenadas como fechas y valores numéricos representados como texto. No hay celdas vacías, lo que muestra que ausencia de vacíos e integridad de la información son propiedades distintas.

Como contraste, al conservar registros dentro de intervalos operativos amplios —age de 1 a 120, trestbps de 1 a 350, chol de 1 a 1500 y thalach de 1 a 300— quedan 289 filas. Sus conteos por clase y las medias de age, trestbps y chol coinciden con las salidas del notebook. Esta coincidencia es compatible con la exclusión de las 31 filas, pero no demuestra el procedimiento completo de limpieza ni la igualdad de todas las celdas.

En ese subconjunto persisten 103 fechas en oldpeak. La vista inicial del notebook muestra valores numéricos para esa variable, sin documentar cómo se obtuvieron. En consecuencia, este informe no atribuye al código una imputación ni una recuperación de valores que no aparecen implementadas.

Análisis exploratorio de los datos

La base que reporta el notebook contiene 160 positivos y 129 negativos. Los positivos representan 55,36 %: aproximadamente 55 de cada 100 registros. Existe una diferencia moderada entre clases; el código no realiza sobremuestreo ni aplica ponderación de clases.

Balance de la variable objetivo

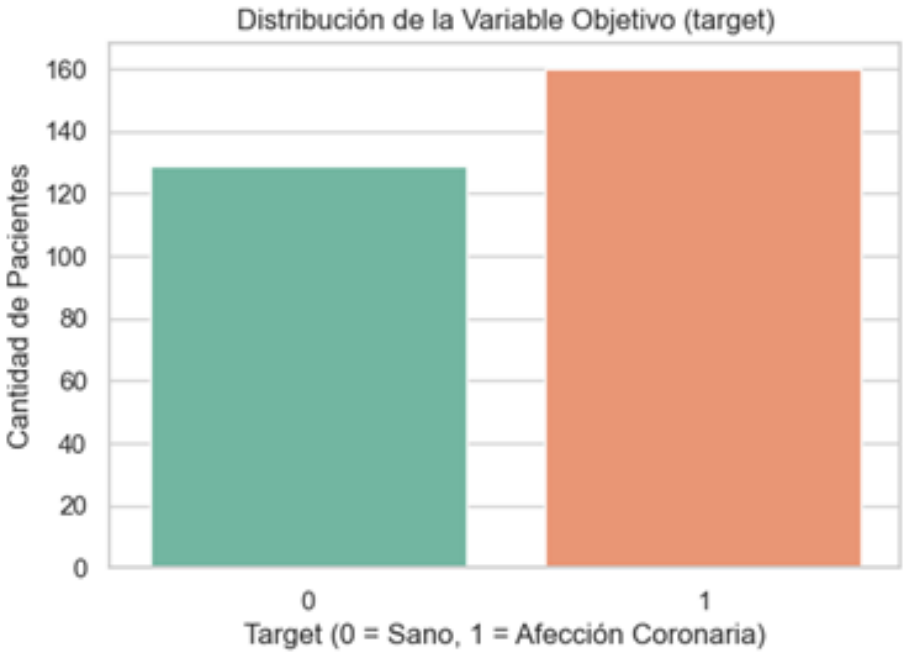


Ilustración 1:Balance de la variable objetivo

Tabla 4:Medias por clase reportadas en el notebook

target	age	trestbps	chol
0	56,67	134,46	253,96
1	52,64	129,18	243,49

La clase 1 tiene medias menores de edad, presión y colesterol en esta muestra. Estas diferencias describen los registros; no establecen factores protectores, causalidad ni patrones generalizables. Las unidades clínicas deben confirmarse con el diccionario de datos.

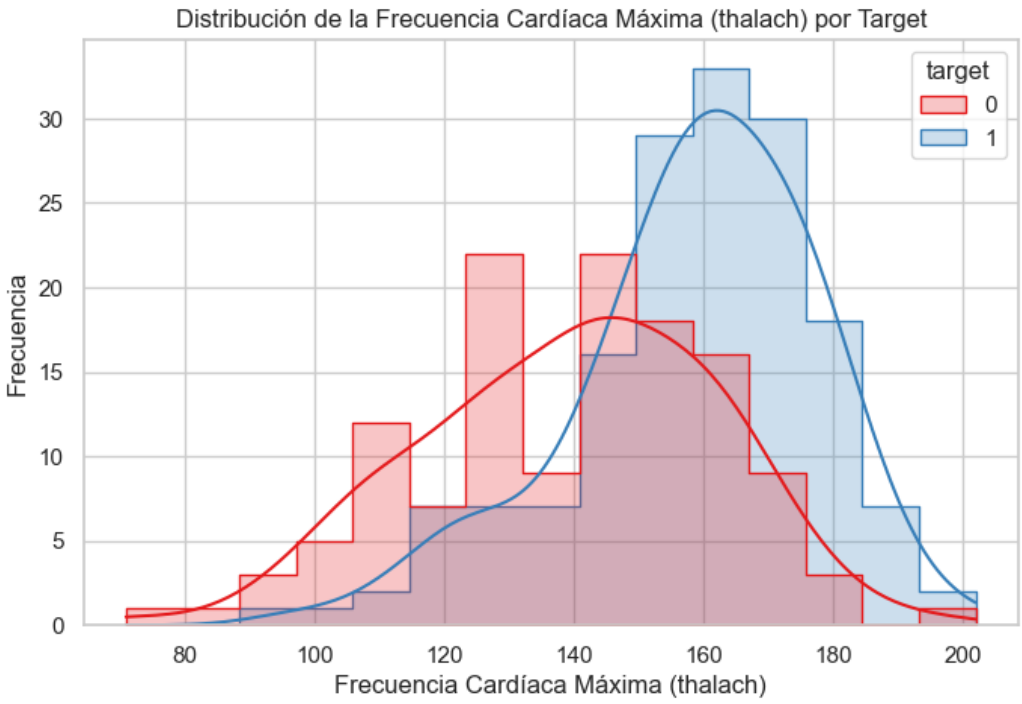


Ilustración 2: Distribución de Thalach según la clase

La distribución de thalach de la clase 1 se desplaza hacia valores mayores, con superposición entre grupos. La variable aporta separación parcial y no basta por sí sola para identificar la clase de todos los registros

Correlación y preparación del modelo



Ilustración 3: Matriz de correlación de las variables continuas y target

La mayor correlación con target entre las continuas corresponde a thalach ($r \approx 0{,}42$). Las asociaciones de age y oldpeak son negativas (ambas $r \approx -0{,}22$), al igual que trestbps ($r \approx -0{,}15$) y chol ($r \approx -0{,}10$). Son relaciones lineales por pares; no equivalen a importancia predictiva ajustada ni explican por qué ocurre una afección. El valor de oldpeak depende, además, de una limpieza no documentada.

Partición y escalamiento

El código usa train_test_split con test_size = 0.2, random_state = 42 y stratify = y. De los 289 registros, 231 se destinan a entrenamiento y 58 a prueba. El reporte de prueba contiene 32 positivos y 26 negativos; por diferencia, entrenamiento contiene 128 positivos y 103 negativos. Estratificar conserva aproximadamente la proporción de clases en ambos conjuntos.

StandardScaler se ajusta únicamente con entrenamiento y se aplica después a prueba en las cinco continuas. La transformación z = (x − μentrenamiento) / σentrenamiento expresa cada medición respecto de la media y desviación del conjunto de entrenamiento. Así, una variable con números grandes no domina solo por su escala. Las 23 indicadoras permanecen sin escalar.

Se entrena LogisticRegression con random_state = 42 y max_iter = 1000. La clasificación utiliza predict, sin ajuste explícito del umbral, con la regla estándar equivalente a 0,50 para la probabilidad positiva. No se implementan Pipeline, imputación, control IQR, validación cruzada ni comparación de algoritmos.

Evaluación de la regresión logística

La evaluación se realiza sobre los 58 registros reservados. La matriz permite reconstruir cuatro de las cinco métricas publicadas y entender el tipo de error que produce el modelo. Las filas representan la clase observada y las columnas la predicción

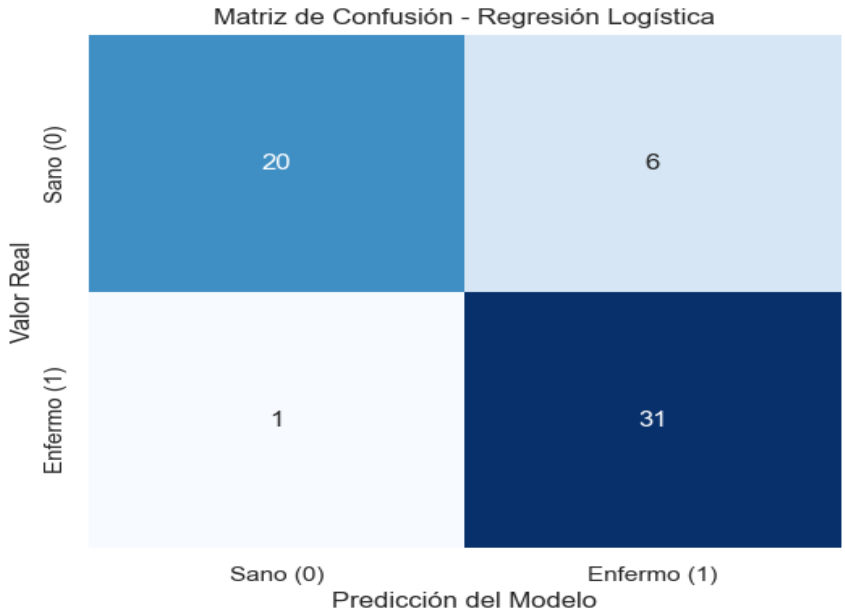


Ilustración 4: Matriz de confusión en el conjunto de prueba

Tabla 5:Métrica de la clase positiva y desempeño global

Métrica	Cálculo o base	Resultado
Exactitud	(20 + 31) / 58	0,8793
Sensibilidad	31 / (31 + 1)	0,9688
Precisión positiva	31 / (31 + 6)	0,8378
F1	2 × 31 / (2 × 31 + 6 + 1)	0,8986
ROC-AUC	Probabilidades y curva ROC	0,9447
Especificidad[1]	20 / (20 + 6)	0,7692

El modelo acierta en 51 registros y se equivoca en siete. Detecta 31 de los 32 positivos y omite uno. Entre las 37 predicciones positivas, seis corresponden a negativos; por eso su precisión es menor que su sensibilidad. El resultado combina una detección alta de positivos con un costo observable de falsas alertas.

Capacidad de discriminación

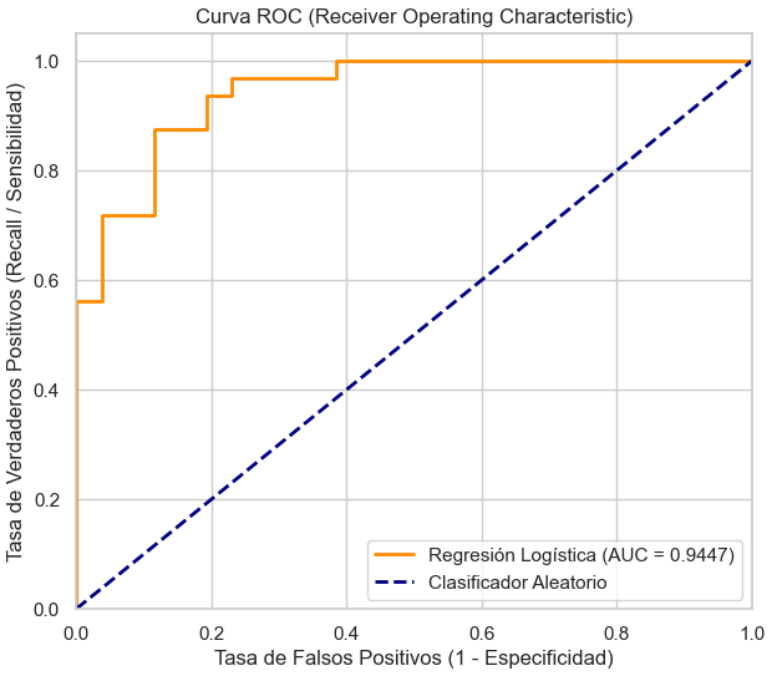


Ilustración 5: Curva ROC de la regresión logística

La curva ROC muestra cómo varía la sensibilidad al aceptar diferentes tasas de falsos positivos. Cada punto corresponde a un umbral distinto aplicado a las probabilidades. La diagonal representa una referencia aleatoria; cuanto más se aproxima la curva al vértice superior izquierdo, mejor es la separación observada entre las clases.

El ROC-AUC de 0,9447 resume esa separación en el conjunto de prueba. Puede interpretarse como la capacidad del modelo para asignar una puntuación mayor a un positivo que a un negativo escogidos al azar, contando los empates de manera proporcional. No significa que el 94,47 % de las predicciones sean correctas: esa proporción corresponde a la exactitud, que aquí es 87,93 %.

A diferencia de la matriz de confusión, el AUC no describe un único umbral. Cambiar el punto de corte modificaría la cantidad de alertas, falsos positivos y falsos negativos, sin cambiar las probabilidades ya obtenidas. El notebook dibuja la curva, pero no selecciona ni valida un umbral alternativo; por ello no se recomienda el valor 0,36 del informe anterior.

Tampoco se evalúa la calibración. Un modelo puede ordenar adecuadamente los casos y, aun así, asignar probabilidades que no reflejen las frecuencias observadas. El AUC favorable sustenta una capacidad de discriminación en esta prueba, no la exactitud clínica de cada probabilidad individual.

Conclusiones

La regresión logística reporta un desempeño favorable en el conjunto reservado: exactitud de 87,93 %, sensibilidad de 96,88 %, precisión positiva de 83,78 %, F1 de 89,86 % y ROC-AUC de 0,9447. La matriz de confusión confirma 31 verdaderos positivos, 20 verdaderos negativos, seis falsos positivos y un falso negativo. Esas cifras sustituyen los resultados del bosque aleatorio y del umbral ajustado que aparecían en el informe original.

El análisis exploratorio muestra un balance moderado de clases y una asociación positiva de thalach con target. Las diferencias descriptivas de edad, presión y colesterol ayudan a conocer la muestra, pero no permiten concluir causalidad ni establecer criterios clínicos de clasificación.

La regresión logística puede respaldarse como modelo inicial del ejercicio por su sensibilidad y capacidad de discriminación observadas. La recomendación se limita a ese papel académico: no existe una comparación empírica que permita declararla superior a otros modelos, ni evidencia externa que autorice generalizar su rendimiento.

Referencias Bibliográficas

- **Corporación Unificada Nacional de Educación Superior [CUN].** (2026). *Caso de estudio: Afección coronaria. Actividad de Construcción Aplicada (ACA 1) - Aplicación de Inteligencia de Negocios*. CUN.

- **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É.** (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

- **Hastie, T., Tibshirani, R., & Friedman, J.** (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

- **Fawcett, T.** (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, *27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

- **Detrano, R., Janosi, A., Steinbrunn, W., Pfisterer, M., Schmid, J., Sandhu, S., Guppy, K., Lee, S., & Froelicher, V.** (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *The American Journal of Cardiology*, *64*(5), 304–310. https://doi.org/10.1016/0002-9149(89)90524-9

Anexos

```python
# ACA: APLICACIÓN DE INTELIGENCIA DE NEGOCIOS
# CASO DE ESTUDIO: AFECCIÓN CORONARIA (REGRESIÓN LOGÍSTICA)

# 2. IMPORTACIÓN DE LIBRERÍAS
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (
    accuracy_score,
    recall_score,
    precision_score,
    f1_score,
    roc_auc_score,
    roc_curve,
    confusion_matrix,
    classification_report
)

# Estilo visual para las gráficas
sns.set_theme(style="whitegrid")

# 3. CARGA DEL DATASET
file_path = 'df_final_limpio.xlsx'
df = pd.read_excel(file_path)
```

```
print(f"Dataset cargado exitosamente con {df.shape[0]} registros y {df.
 ↪shape[1]} columnas.")
display(df.head())

# 4. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

# 4.1. Análisis de Balanceo del Target
print("\n" + "="*50)
print("1. ANÁLISIS DE BALANCEO DEL TARGET")
print("="*50)
target_counts = df['target'].value_counts()
print(target_counts)
print(f"Proporción Clase 1 (Enfermo): {df['target'].mean()*100:.2f}%")
print(f"Proporción Clase 0 (Sano): {(1 - df['target'].mean())*100:.2f}%")

# Gráfica de balanceo
plt.figure(figsize=(6, 4))
sns.countplot(data=df, x='target', palette='Set2')
plt.title('Distribución de la Variable Objetivo (target)')
plt.xlabel('Target (0 = Sano, 1 = Afección Coronaria)')
plt.ylabel('Cantidad de Pacientes')
plt.show()

# 4.2. Perfil del Paciente (Estadística Descriptiva por Grupo)
print("\n" + "="*50)
print("2. PERFIL DEL PACIENTE (MEDIAS POR GRUPO)")
print("="*50)
perfil_paciente = df.groupby('target')[['age', 'trestbps', 'chol']].mean()
display(perfil_paciente)

# 4.3. Visualización de Distribución para 'thalach' (Frecuencia Cardíaca Máxima)
plt.figure(figsize=(8, 5))
sns.histplot(data=df, x='thalach', hue='target', kde=True, element="step",␣
 ↪palette='Set1')
plt.title('Distribución de la Frecuencia Cardíaca Máxima (thalach) por Target')
plt.xlabel('Frecuencia Cardíaca Máxima (thalach)')
plt.ylabel('Frecuencia')
plt.show()

# 4.4. Matriz de Correlación
plt.figure(figsize=(10, 8))
corr_matrix = df[['target', 'age', 'trestbps', 'chol', 'thalach', 'oldpeak']].
 ↪corr()
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f", linewidths=0.5)
plt.title('Matriz de Correlación de Variables Clave')
plt.show()
```

```
# 5. PREPROCESAMIENTO Y DIVISIÓN DE DATOS

X = df.drop(columns=['target'])
y = df['target']

# División Train-Test (80% entrenamiento, 20% prueba) con estratificación
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# Escalamiento de variables continuas
cols_a_escalar = ['age', 'trestbps', 'chol', 'thalach', 'oldpeak']
scaler = StandardScaler()

X_train_scaled = X_train.copy()
X_test_scaled = X_test.copy()

X_train_scaled[cols_a_escalar] = scaler.fit_transform(X_train[cols_a_escalar])
X_test_scaled[cols_a_escalar] = scaler.transform(X_test[cols_a_escalar])

print("\nPreprocesamiento completado: Escalamiento aplicado correctamente sin␣
 ↪fuga de datos.")


# 6. ENTRENAMIENTO DEL MODELO DE REGRESIÓN LOGÍSTICA

modelo_lr = LogisticRegression(random_state=42, max_iter=1000)
modelo_lr.fit(X_train_scaled, y_train)

y_pred = modelo_lr.predict(X_test_scaled)
y_prob = modelo_lr.predict_proba(X_test_scaled)[:, 1]


# 7. EVALUACIÓN Y MÉTRICAS DEL MODELO

acc = accuracy_score(y_test, y_pred)
rec = recall_score(y_test, y_pred)
prec = precision_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
auc = roc_auc_score(y_test, y_prob)

print("\n" + "="*50)
print("3. RESULTADOS DEL MODELO DE REGRESIÓN LOGÍSTICA")
print("="*50)
print(f"Accuracy (Exactitud):            {acc:.4f}")
print(f"Recall (Sensibilidad - CLAVE):   {rec:.4f}")
```

```
print(f"Precisión:                          {prec:.4f}")
print(f"F1-Score:                           {f1:.4f}")
print(f"ROC-AUC:                            {auc:.4f}")

print("\nReporte de Clasificación Detallado:")
print(classification_report(y_test, y_pred))

# 7.1. Matriz de Confusión
cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(6, 5))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', cbar=False,
            xticklabels=['Sano (0)', 'Enfermo (1)'],
            yticklabels=['Sano (0)', 'Enfermo (1)'])
plt.title('Matriz de Confusión - Regresión Logística')
plt.xlabel('Predicción del Modelo')
plt.ylabel('Valor Real')
plt.show()

# 7.2. Curva ROC - AUC
fpr, tpr, thresholds = roc_curve(y_test, y_prob)

plt.figure(figsize=(7, 6))
plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'Regresión Logística (AUC =␣
 ↪{auc:.4f})')
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--',␣
 ↪label='Clasificador Aleatorio')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('Tasa de Falsos Positivos (1 - Especificidad)')
plt.ylabel('Tasa de Verdaderos Positivos (Recall / Sensibilidad)')
plt.title('Curva ROC (Receiver Operating Characteristic)')
plt.legend(loc="lower right")
plt.show()
```