Implementación e interpretación de modelos de Machine Learning para la retención de usuarios de Mercado Libre

ACA 1 – Machine Learning (30 %)

Modalidad de entrega: consolidada

Liberney Ardila Sepúlveda
Michell Dayana Carrillo López
Jonh Alejandro Garzón Pinzón
Julián Andrés Mancera García
Sandra Moreno Rueda

Corporación Unificada Nacional de Educación Superior (CUN)
Especialización en Analítica de Datos

Machine Learning – 51ET1 – Segundo bloque (26ES4)
Docente: Miguel Alfonso Martínez Barragán
1 de noviembre de 2026

Contenido

Introducción.....3
Contexto del negocio y preguntas de análisis.....3
Fuente de datos y modalidad de entrega.....4
Diccionario de datos.....4
Desarrollo del caso.....6
Herramientas y entorno de ejecución.....6
Preparación de los datos.....7
Implementación de los modelos.....8
Resultados.....10
Clasificación de la fuga.....10
Comparación según la modalidad consolidada.....13
Interpretación de la regresión logística.....15
Regresión lineal.....16
Interpretación de resultados.....20
Limitaciones.....21
Conclusiones.....22
Recomendaciones y trabajo futuro.....23
Referencias.....24
Anexo A. Evidencias de ejecución.....25
A.1. Carga y exploración de los datos.....27
A.2. Regresión logística (run_log_reg_001).....28
A.3. SVM con kernel RBF (run_svm_rbf_002).....30
A.4. Random Forest (run_rand_forest_003).....32
A.5. Regresión lineal (run_lin_reg_004).....37
A.6. Comparación de los clasificadores en MLflow.....39

Introducción

El comercio electrónico depende de la capacidad de las plataformas para comprender el comportamiento de sus usuarios, fortalecer la retención y orientar las acciones de fidelización. Mercado Libre S. A. es una plataforma de comercio electrónico y servicios financieros de América Latina; en ese contexto, anticipar qué compradores están en riesgo de abandonar la plataforma y estimar cuánto gastarán durante el año permite a los equipos de relaciones con clientes (CRM) priorizar campañas y asignar recursos con base en información cuantitativa.

Este informe desarrolla cuatro modelos de aprendizaje automático sobre un conjunto de datos académico de 500 usuarios: tres clasificadores (regresión logística, SVM con kernel RBF y Random Forest) que estiman si un usuario presenta fuga, y una regresión lineal que estima su gasto anual en dólares estadounidenses (USD). La entrega es **consolidada**: los tres clasificadores se entrenan y evalúan sobre la misma muestra y la misma partición, y la regresión lineal se presenta por separado.

Contexto del negocio y preguntas de análisis

Mercado Libre opera un sistema de ventas en línea en el que cada usuario acumula un historial de compras, reclamos, nivel en el programa de beneficios y tiempo de navegación. Esa información alimenta los procesos de retención del área CRM: identificar usuarios con riesgo de inactividad, definir campañas personalizadas y reconocer los segmentos de mayor valor. A partir de ese proceso de negocio se plantean dos preguntas de análisis.

> **Pregunta de clasificación**
> ¿Es posible predecir si un usuario presentará fuga (inactividad o abandono de la plataforma) a partir de su comportamiento de compra, su actividad en la aplicación, sus reclamos y su nivel de fidelidad?

> **Pregunta de regresión**
> ¿Cómo se puede estimar el gasto anual de un usuario, expresado en USD, a partir de sus variables demográficas, transaccionales y de interacción digital?

Fuente de datos y modalidad de entrega

Los datos provienen del archivo `dataset_mercadolibre_aca1.xlsx`, suministrado para la actividad, que contiene 500 registros y 11 columnas. Cada registro representa a un usuario registrado de la plataforma y reúne características demográficas (edad), transaccionales (compras, ticket promedio, reclamos y nivel de fidelidad) y de interacción digital (horas de uso de la aplicación). El ejercicio es académico: no constituye un análisis de los registros internos reales de Mercado Libre.

500 usuarios (registros)	**7 → 9** entradas antes → después de codificar	**3,6 %** fuga: 18 de 500 usuarios	**2.914,45 USD** gasto anual medio

El grupo eligió la modalidad **consolidada**. Los tres clasificadores usan la misma muestra, la misma partición de entrenamiento y prueba (la misma semilla y las mismas 100 observaciones de prueba, 4 de ellas con fuga) y la misma variable objetivo, de modo que sus curvas ROC son comparables. La regresión lineal predice una variable numérica distinta, el gasto anual, a partir de las mismas entradas, y sus resultados se presentan por separado con las métricas propias de regresión.

Diccionario de datos

La Tabla 1 presenta el diccionario de datos, elaborado a partir del archivo de diccionario entregado para la actividad y verificado con las estadísticas descriptivas del conjunto. Se utilizan **siete variables de entrada originales**, dentro del rango de cinco a diez exigido, contadas antes de la codificación y sin incluir las variables objetivo. La variable categórica `nivel_fidelidad` viene codificada en el archivo mediante tres columnas indicadoras (*one-hot*): `nivel_Básico`, `nivel_Medio` y `nivel_VIP`; por ello, los modelos reciben **nueve columnas de entrada**. `fuga` es el objetivo de clasificación y `gasto_anual` es el objetivo de la regresión lineal.

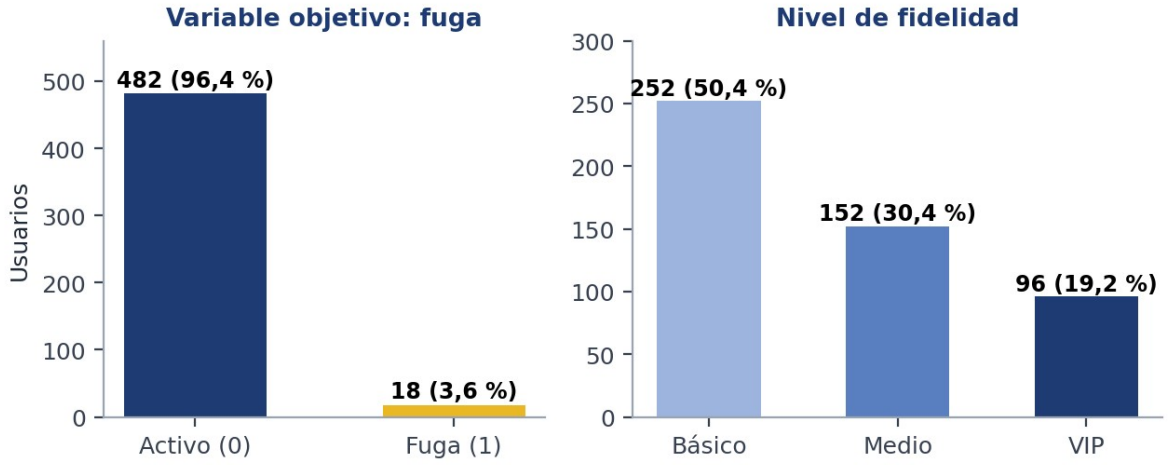
Tabla 1
Diccionario de datos del conjunto de Mercado Libre

Variable	Descripción	Tipo	Unidad o categorías (rango observado)	Rol
edad	Edad del usuario registrado en la plataforma	Numérica continua	Años (18 a 69)	Entrada
antiguedad_cuenta	Tiempo desde la creación de la cuenta	Numérica continua	Meses (1 a 71)	Entrada
compras_ult_anio	Transacciones de compra en los últimos 12 meses	Numérica discreta	Número de compras (0 a 39)	Entrada
ticket_promedio	Valor monetario promedio por orden de compra	Numérica continua	USD (16,16 a 249,86)	Entrada
reclamos_abiertos	Disputas o tickets de soporte técnico gestionados	Numérica discreta	Número de reclamos (0 a 4)	Entrada
horas_app	Promedio de horas mensuales de navegación en la app móvil	Numérica continua	Horas por mes (0,50 a 29,85)	Entrada
nivel_fidelidad (nivel_Básico, nivel_Medio, nivel_VIP)	Nivel en el programa de beneficios; en el archivo está codificado en tres columnas indicadoras	Categórica (3 binarias)	Básico (50,4 %), Medio (30,4 %), VIP (19,2 %)	Entrada (3 columnas)
fuga	1 = usuario inactivo o fugado; 0 = usuario activo	Binaria	0 / 1 (fuga: 3,6 %)	Objetivo de clasificación
gasto_anual	Monto total gastado por el usuario durante el año	Numérica continua	USD (10,00 a 9.265,23)	Objetivo de regresión

Nota. Descripciones, tipos y roles según el archivo de diccionario de datos de la actividad; los rangos observados se calcularon con `describe()` sobre los 500 registros (Figura A2). Los rangos nominales del diccionario son 18 a 70 años y 1 a 72 meses.

La variable `fuga` presenta un desbalance marcado: 482 usuarios activos (96,4 %) y solo 18 con fuga (3,6 %) (Figura 1). En la partición de entrenamiento (400 registros) quedan 14 casos de fuga y en la de prueba (100 registros), 4. Este desbalance condiciona toda la evaluación: un modelo que clasificara a todos los usuarios como activos alcanzaría 96 % de exactitud sin detectar una sola fuga.

Figura 1
Distribución de la variable objetivo y del nivel de fidelidad



Nota. Conteos sobre los 500 registros del conjunto de datos.

Desarrollo del caso

Herramientas y entorno de ejecución

La preparación de los datos y la implementación de los modelos se realizaron en Jupyter Notebook, de forma local, con Python 3.13. Se emplearon pandas para la carga y manipulación de los datos, scikit-learn 1.9.1 (Pedregosa et al., 2011) para el preprocesamiento, el entrenamiento y la evaluación, matplotlib y seaborn para las gráficas, y MLflow (Zaharia et al., 2018) para registrar los parámetros y las métricas de las cuatro ejecuciones, denominadas `run_log_reg_001`, `run_svm_rbf_002`, `run_rand_forest_003` y `run_lin_reg_004`. Los cuadernos de práctica se adaptaron a los datos del caso; las adaptaciones se describen en cada modelo. Las figuras del cuerpo del informe presentan, con un diseño unificado, los resultados de esas ejecuciones; las capturas originales de cada ejecución se incluyen en el Anexo A.

Preparación de los datos

Carga y exploración

El archivo se leyó con pandas (`read_excel`) y se confirmó que contiene 500 registros y 11 columnas (Figura A1). Se revisaron los tipos de datos, los valores faltantes y los duplicados, y se calcularon estadísticas descriptivas con `describe()` (Figura A2): la variable `fuga` tiene media de 0,036 (18 usuarios con fuga entre 500) y `gasto_anual` tiene media de 2.914,45 USD y desviación estándar de 2.158,29 USD.

Valores faltantes y duplicados

`describe()` reporta 500 valores no nulos en cada una de las 11 columnas y no hay registros duplicados; por tanto, no fue necesario eliminar ni imputar registros. El flujo de la regresión lineal incluye de todos modos un imputador por mediana, que no modifica los datos cuando no hay faltantes.

Codificación

La variable `nivel_fidelidad` ya venía codificada en el archivo mediante tres columnas indicadoras (*one-hot*), de modo que las siete entradas originales se convierten en nueve columnas (seis numéricas y tres binarias). No se aplicó una codificación adicional.

Partición y escalamiento

Antes de ajustar cualquier transformación, los datos se dividieron con `train_test_split` (`test_size = 0.20`, `random_state = 42`, `stratify = y`), lo que dejó 400 registros de entrenamiento y 100 de prueba, con proporciones de fuga de 3,5 % (14 casos) y 4,0 % (4 casos). `StandardScaler` se ajustó (*fit*) únicamente con el conjunto de entrenamiento y luego se aplicó (*transform*) al conjunto de prueba, de modo que ninguna estadística de la prueba influye en las transformaciones. En la regresión logística y la SVM el escalador se aplicó a las nueve columnas; en Random Forest, solo a las seis variables continuas,

puesto que los árboles no dependen de la escala. Los tres clasificadores comparten la misma partición, por lo que sus curvas ROC se calculan sobre las mismas 100 observaciones de prueba.

Preparación para la regresión lineal

Para estimar `gasto_anual` se usaron las mismas nueve columnas de entrada (sin `fuga` ni `gasto_anual`) y una partición 80/20 con `random_state = 42`, sin estratificar, con 100 registros de prueba. La regresión lineal por mínimos cuadrados ordinarios no requiere escalamiento y no se aplicó.

Implementación de los modelos

La Tabla 2 resume la configuración de las cuatro ejecuciones registradas en MLflow. A continuación se explican las etapas de cada una y las adaptaciones realizadas respecto de los cuadernos de práctica.

Tabla 2
Configuración de las cuatro ejecuciones

Ejecución (MLflow)	Modelo	Configuración	Umbral
run_log_reg_001	Regresión logística	`class_weight = 'balanced'`; `max_iter = 1000`; `random_state = 42`; penalización L2, `C = 1,0` y solver `lbfgs` (valores por defecto); 9 entradas escaladas	0,50
run_svm_rbf_002	SVM	`kernel = 'rbf'`; `C = 1,0`; `gamma = 'scale'` (por defecto); `probability = True`; `random_state = 42`; 9 entradas escaladas	0,04
run_rand_forest_003	Random Forest	`n_estimators = 100`; `class_weight = 'balanced'`; `random_state = 42`; 9 entradas (6 continuas escaladas)	0,15
run_lin_reg_004	Regresión lineal	*Pipeline* con imputación por mediana y mínimos cuadrados ordinarios (`fit_intercept = True`); 9 entradas; objetivo `gasto_anual`	No aplica

Nota. Parámetros tomados de los cuadernos y de la comparación de ejecuciones en MLflow (Figuras A23 a A26). Los valores marcados como “por defecto” son los de scikit-learn.

Regresión logística (run_log_reg_001)

La regresión logística estima la probabilidad de fuga mediante una función logística aplicada a una combinación lineal de las características (Hosmer et al., 2013). Las etapas fueron:

(a) carga del archivo y definición de las nueve entradas y del objetivo `fuga`; (b) partición estratificada 80/20; (c) escalamiento con `StandardScaler` ajustado solo con el entrenamiento; (d) entrenamiento de `LogisticRegression` con la configuración de la Tabla 2; y (e) cálculo de las probabilidades de la clase positiva con `predict_proba`, clasificación con el umbral de 0,50 y evaluación con la matriz de confusión, el reporte de clasificación y el ROC-AUC. Las adaptaciones respecto del cuaderno de práctica fueron la estratificación de la partición, el ajuste del escalador solo con entrenamiento, `class_weight = 'balanced'` para compensar el desbalance (96 % frente a 4 %) y el cálculo de coeficientes y razones de probabilidades (*odds ratios*) para interpretar el modelo.

SVM con kernel RBF (run_svm_rbf_002)

La máquina de soporte vectorial (Cortes y Vapnik, 1995) con kernel RBF permite fronteras de decisión no lineales; el escalamiento es especialmente relevante porque el kernel se basa en distancias. Las etapas fueron: (a) separación de las entradas, excluyendo `fuga` y `gasto_anual`; (b) partición 80/20 estratificada; (c) escalamiento ajustado solo con el entrenamiento; (d) entrenamiento de `SVC` con `probability = True`, necesario para obtener probabilidades, trazar la curva ROC y calcular el AUC; y (e) evaluación con las probabilidades de la clase positiva. La adaptación principal fue el umbral: con el valor por defecto (0,50) el modelo clasificó a todos los usuarios como activos, con exactitud de 96 % y recall de fuga igual a 0. Por ello se reemplazó `predict()` por `predict_proba()` y se fijó un umbral de 0,04 para la clasificación final.

Random Forest (run_rand_forest_003)

Random Forest (Breiman, 2001) combina 100 árboles de decisión y promedia sus probabilidades. Las etapas fueron: (a) definición de las nueve características; (b) partición 80/20 estratificada antes de transformar; (c) escalamiento de las seis variables continuas con ajuste solo en entrenamiento; (d) entrenamiento de `RandomForestClassifier`; (e) cálculo de las

probabilidades de la clase positiva con `predict_proba` y conversión a etiquetas con un umbral de 0,15; y (f) evaluación con la matriz de confusión, el reporte de clasificación y el ROC-AUC. Las adaptaciones fueron la estratificación, `class_weight = 'balanced'` para dar mayor peso a los errores de la clase minoritaria, un umbral de 0,15, inferior al convencional de 0,50, que favorece la detección de fugas a costa de más falsos positivos, y la visualización de cinco árboles individuales del ensamble (`plot_tree`, `max_depth = 3`) para ilustrar que cada estimador realiza divisiones distintas (Figuras A13 a A17). El fragmento de código se incluye en el Anexo A (Figura A18).

Regresión lineal (run_lin_reg_004)

La regresión lineal estima `gasto_anual` como una combinación lineal de las nueve entradas. Las etapas fueron: (a) partición 80/20 con `random_state = 42`; (b) construcción de un *pipeline* con imputación por mediana y regresión lineal por mínimos cuadrados ordinarios; (c) predicción sobre los 100 registros de prueba; (d) cálculo del error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2); y (e) gráficas de valores reales frente a predichos y de residuos. No se usa ROC-AUC porque esa métrica corresponde a clasificación.

> **Criterio de selección de los umbrales**
> Los umbrales de 0,04 (SVM) y 0,15 (Random Forest) se fijaron explorando resultados sobre el conjunto de prueba y no con un conjunto de validación independiente. Por eso las métricas que dependen del umbral (exactitud, precisión, recall y F1) deben leerse como descriptivas de estas ejecuciones y no como evidencia de superioridad de un algoritmo (véase Limitaciones).

Resultados

Clasificación de la fuga

La clase positiva es `fuga = 1` (usuario inactivo o fugado). La evaluación se hizo sobre las mismas 100 observaciones de prueba, 4 de ellas con fuga. La Tabla 3 reúne las métricas

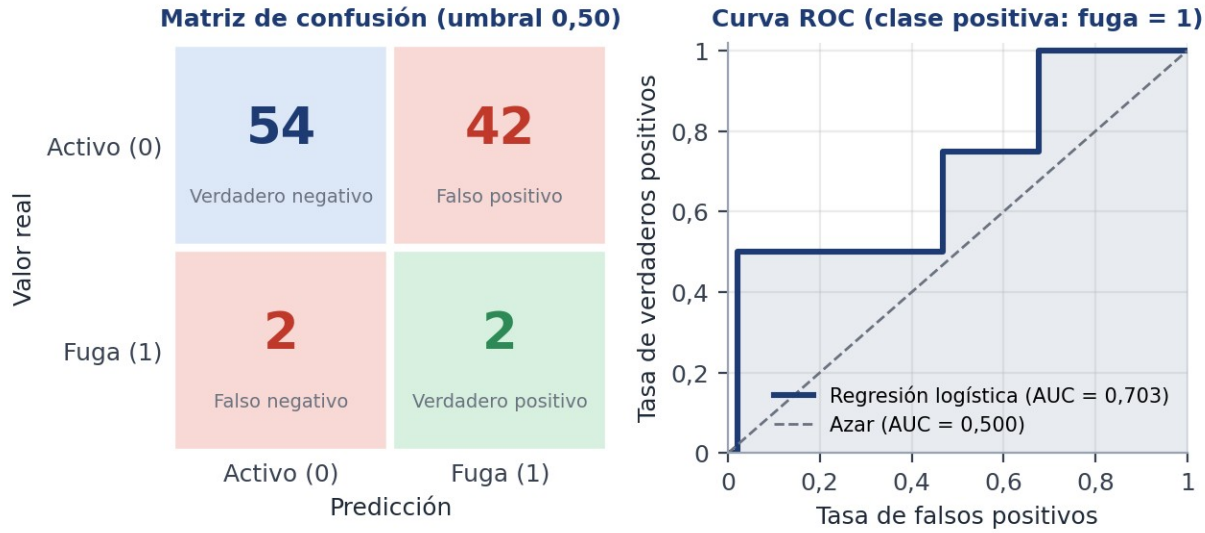
registradas en MLflow y las Figuras 2 a 4 muestran, para cada modelo, la matriz de confusión con su umbral y la curva ROC calculada con las probabilidades de la clase positiva.

Tabla 3
Métricas de clasificación sobre el conjunto de prueba (n = 100; 4 fugas)

Métrica	Regresión logística	SVM (RBF)	Random Forest
Umbral de decisión	0,50	0,04	0,15
Exactitud	0,560	0,850	0,740
Precisión (fuga = 1)	0,045	0,133	0,042
Recall (fuga = 1)	0,500	0,500	0,250
F1 (fuga = 1)	0,083	0,211	0,071
Precisión (activo = 0)	0,964	0,976	0,961
Recall (activo = 0)	0,563	0,865	0,760
F1 (activo = 0)	0,711	0,917	0,849
ROC-AUC	0,703	0,620	0,540

Nota. Valores registrados en MLflow. El AUC se calculó con las probabilidades de la clase positiva; con más decimales son 0,7031 (regresión logística), 0,6198 (SVM) y 0,5404 (Random Forest).

Figura 2
Regresión logística: matriz de confusión y curva ROC

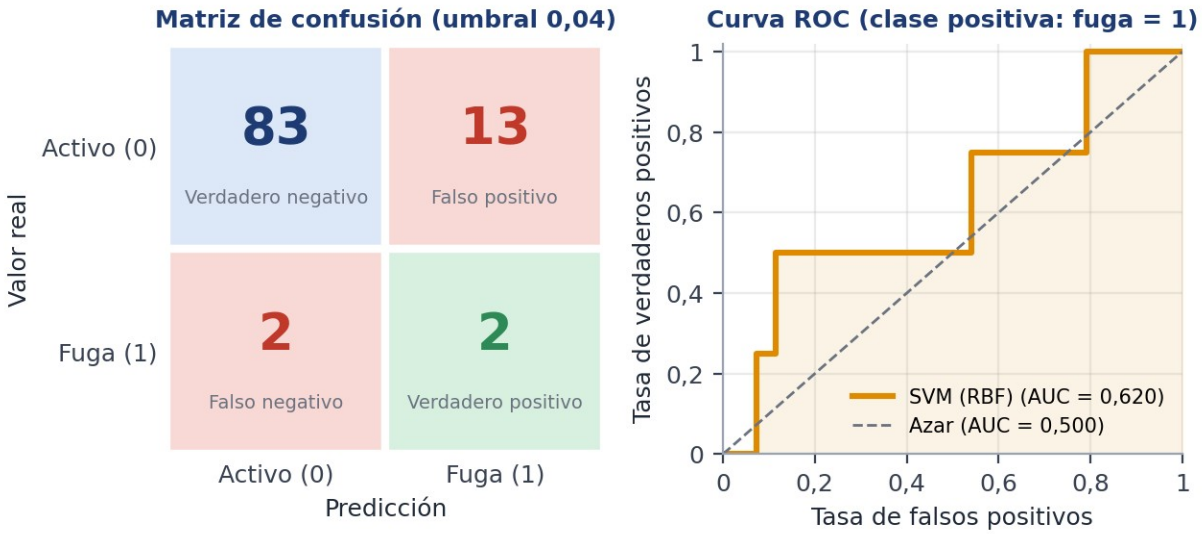


Nota. VN = verdaderos negativos; FP = falsos positivos; FN = falsos negativos; VP = verdaderos positivos. Clase positiva: fuga = 1.

Lectura

Con el umbral de 0,50 la regresión logística detecta 2 de las 4 fugas (recall de 0,50), pero genera 42 falsas alarmas entre los 96 usuarios activos (precisión de 0,045). Tiene el AUC más alto de los tres modelos (0,703).

Figura 3
SVM con kernel RBF: matriz de confusión y curva ROC

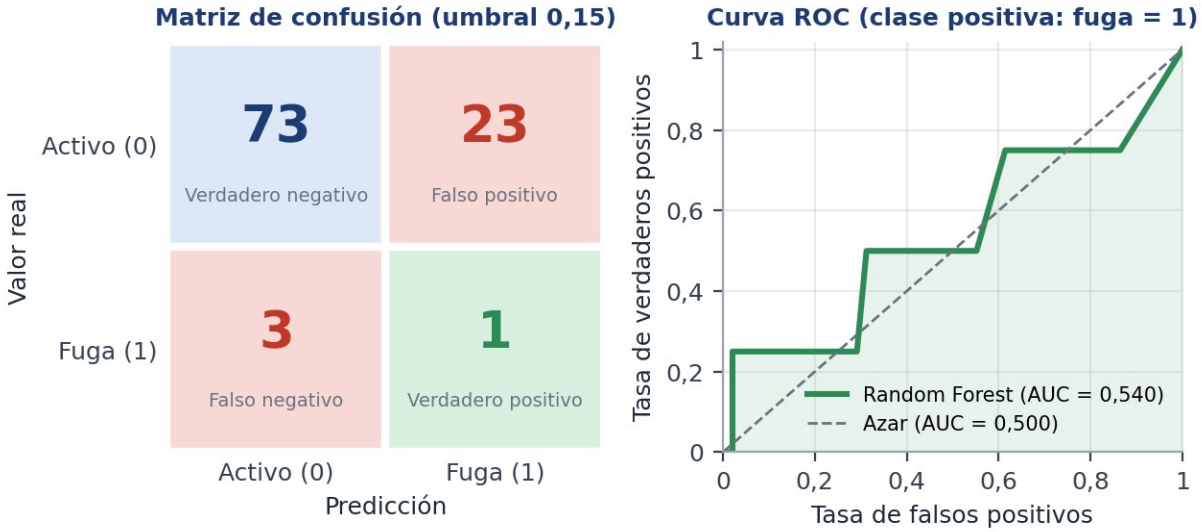


Nota. Umbral de decisión de 0,04, aplicado a las probabilidades de la clase positiva.

Lectura

Con el umbral de 0,04 la SVM detecta también 2 de las 4 fugas, pero con 13 falsas alarmas (precisión de 0,133 y F1 de 0,211): la mejor relación entre ambos tipos de error en esta ejecución. Su AUC (0,620) es menor que el de la regresión logística.

Figura 4
Random Forest: matriz de confusión y curva ROC



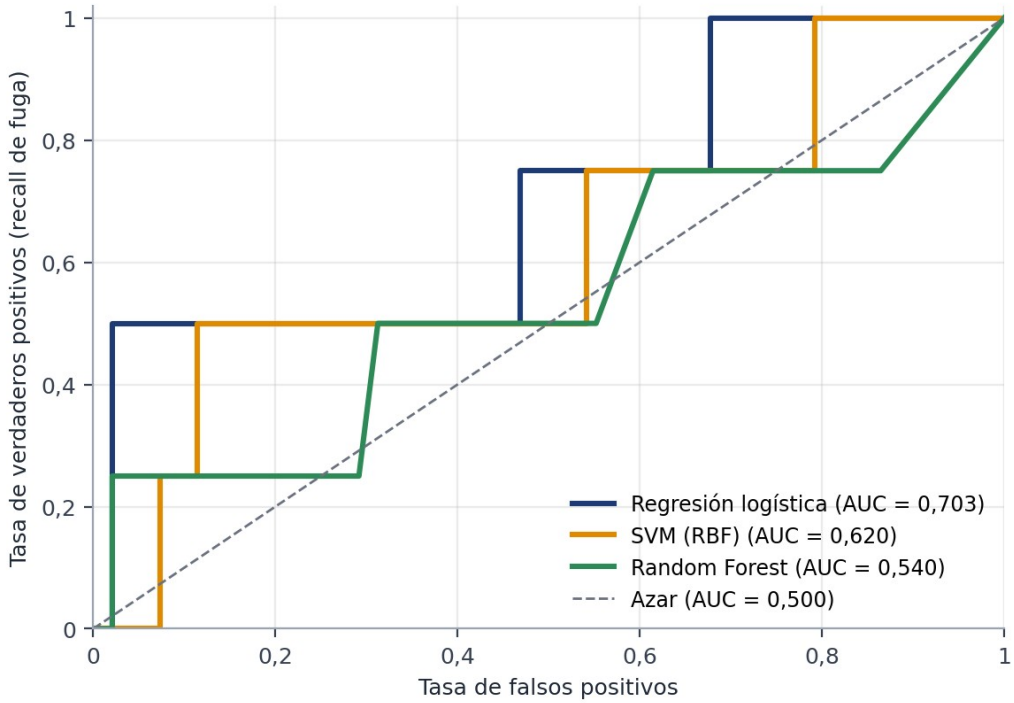
Nota. Umbral de decisión de 0,15, aplicado a las probabilidades de la clase positiva.

> **Lectura**
> Con el umbral de 0,15 Random Forest detecta 1 de las 4 fugas con 23 falsas alarmas (recall de 0,25; precisión de 0,042). Su AUC (0,540) está cerca del valor de azar (0,500): el modelo ordena casi igual que una clasificación aleatoria.

Comparación según la modalidad consolidada

Los tres clasificadores se evaluaron sobre las mismas 100 observaciones de prueba y con la misma variable objetivo, por lo que sus curvas ROC y sus AUC pueden compararse (Figura 5). El orden observado es regresión logística (0,703), SVM (0,620) y Random Forest (0,540). Sin embargo, la prueba contiene solo 4 casos positivos, es decir, 4 × 96 = 384 pares formados por un caso positivo y uno negativo. Con ese tamaño, el error estándar aproximado del AUC (Hanley y McNeil, 1982) es de alrededor de 0,15 para cada modelo (Tabla 4), mayor que las diferencias observadas entre ellos; los intervalos de la Figura 6 se solapan casi por completo. Por eso estos resultados **no permiten afirmar que un modelo sea superior a otro**.

Figura 5
Curvas ROC comparativas de los tres clasificadores



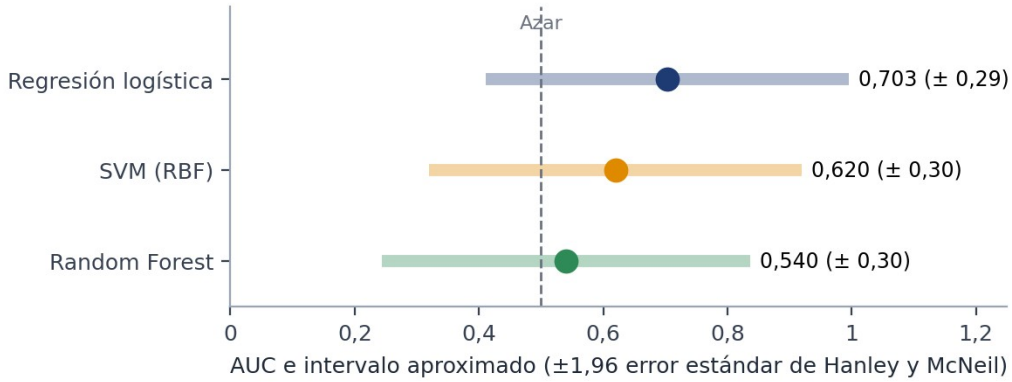
Nota. Las tres curvas se calcularon sobre las mismas 100 observaciones de prueba (4 fugas). La diagonal punteada representa un clasificador sin capacidad de discriminación.

Tabla 4
AUC y error estándar aproximado de cada clasificador

Modelo	AUC	Error estándar (aprox.)	Intervalo aprox. (±1,96 EE)
Regresión logística	0,703	0,149	0,41 a 1,00
SVM (RBF)	0,620	0,153	0,32 a 0,92
Random Forest	0,540	0,151	0,24 a 0,84

Nota. Error estándar calculado con la aproximación de Hanley y McNeil (1982) para 4 casos positivos y 96 negativos; es una estimación gruesa, dada la cantidad de casos positivos.

Figura 6
AUC con intervalo aproximado de cada clasificador



Nota. Los intervalos son aproximados y sirven para dimensionar la incertidumbre, no para contrastar hipótesis.

Las métricas que dependen del umbral (exactitud, precisión, recall y F1) tampoco son directamente comparables entre modelos, porque cada uno usó un umbral distinto (0,50; 0,04 y 0,15) y las probabilidades de algoritmos diferentes no tienen la misma escala. Por ejemplo, la exactitud más alta (0,850, SVM) refleja en buena parte la dominancia de la clase activa y no una mejor detección de fugas: ningún modelo detectó más de 2 de las 4 fugas.

Interpretación de la regresión logística

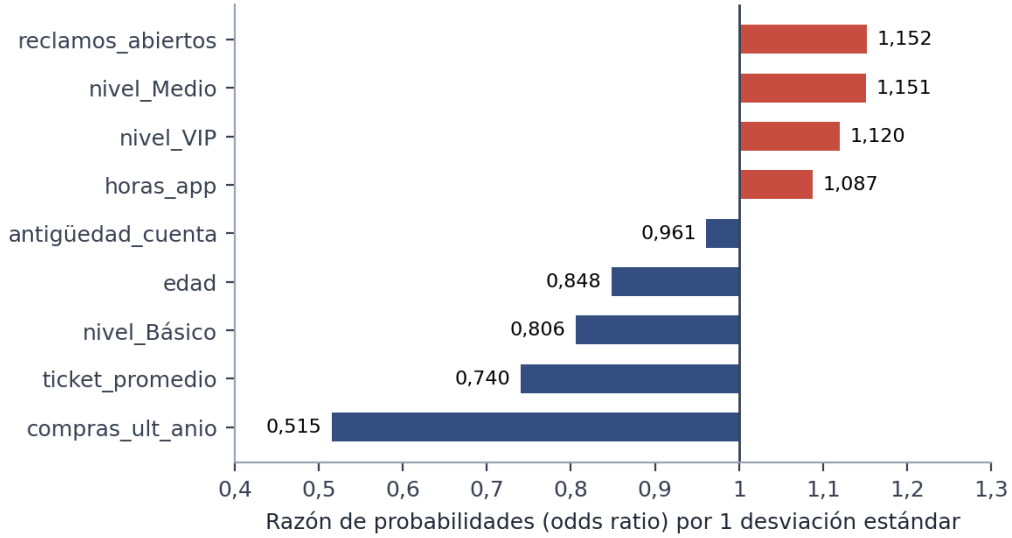
Como las variables numéricas se estandarizaron, cada razón de probabilidades se interpreta por cada aumento de una desviación estándar de la variable, manteniendo constantes las demás. `compras_ult_anio` presentó la asociación negativa más fuerte con la fuga (β = -0,663; OR = 0,515, es decir, probabilidades de fuga aproximadamente 48,5 % menores por cada desviación estándar adicional), seguida de `ticket_promedio` (OR = 0,740) y `edad` (OR = 0,848). Entre las asociaciones positivas destacan `reclamos_abiertos` (OR = 1,152) y `horas_app` (OR = 1,087) (Tabla 5 y Figura 7). Los datos descriptivos son coherentes con ese patrón: los 18 usuarios con fuga realizaron en promedio 13,8 compras en el último año frente a 20,7 de los activos, tuvieron un ticket promedio de 107,11 USD frente a 134,43 USD y 1,39 reclamos abiertos frente a 0,99.

Tabla 5
Coeficientes y razones de probabilidades de la regresión logística

Variable	Coeficiente (β)	Odds ratio (e^β)	Sentido
reclamos_abiertos	0,141	1,152	Asociada con mayor fuga
nivel_Medio	0,140	1,151	Asociada con mayor fuga
nivel_VIP	0,113	1,120	Asociada con mayor fuga
horas_app	0,084	1,087	Asociada con mayor fuga
antiguedad_cuenta	-0,040	0,961	Asociada con menor fuga
edad	-0,164	0,848	Asociada con menor fuga
nivel_Básico	-0,216	0,806	Asociada con menor fuga
ticket_promedio	-0,301	0,740	Asociada con menor fuga
compras_ult_anio	-0,663	0,515	Asociada con menor fuga

Nota. Modelo entrenado con las nueve columnas de entrada escaladas. Las asociaciones no implican causalidad. Las tres columnas de `nivel_fidelidad` son indicadoras de una misma variable, por lo que sus coeficientes no deben leerse de forma aislada. Con solo 18 casos de fuga, los coeficientes pueden ser inestables.

Figura 7
Razones de probabilidades de la regresión logística



Nota. Valores superiores a 1 indican mayor probabilidad de fuga; inferiores a 1, menor probabilidad.

Regresión lineal

Los resultados de la regresión lineal se presentan por separado, con las métricas propias de regresión; no se comparan con el AUC de los clasificadores porque miden aspectos distintos de tareas distintas.

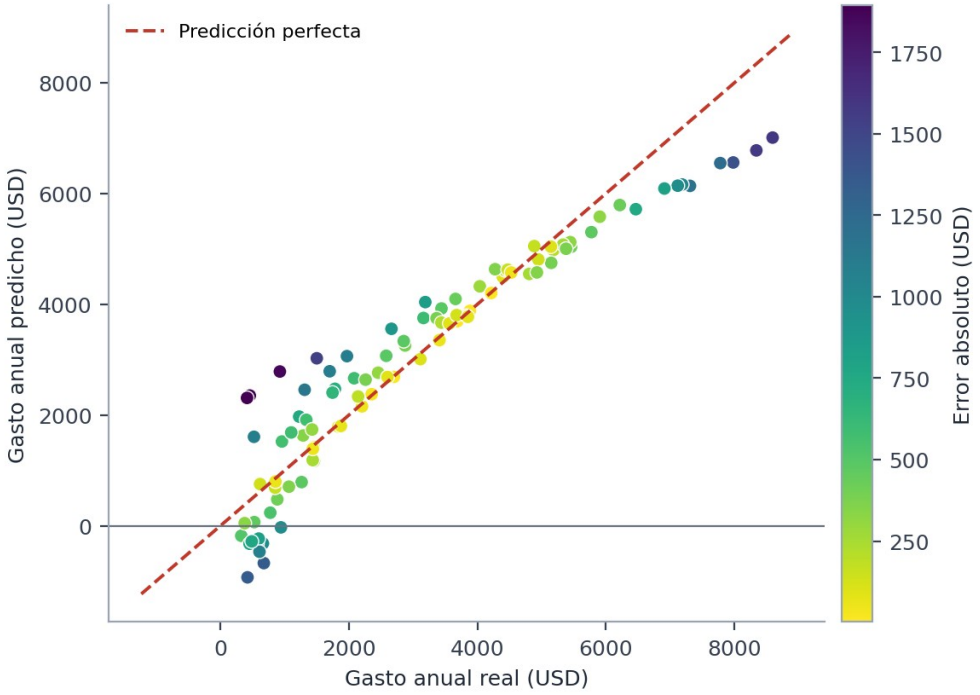
Tabla 6
Métricas de la regresión lineal para gasto_anual (run_lin_reg_004)

Métrica	Valor	Significado
MAE	538,87 USD	Error absoluto promedio entre el gasto real y el estimado
RMSE	716,21 USD	Raíz del error cuadrático medio; penaliza más los errores grandes
R^2	0,8895	Proporción de la variabilidad de gasto_anual explicada por el modelo

Nota. Valores del experimento MercadoLibre_Regresion_Gasto en MLflow, sobre 100 registros de prueba. MAE y RMSE están en las unidades de `gasto_anual` (USD).

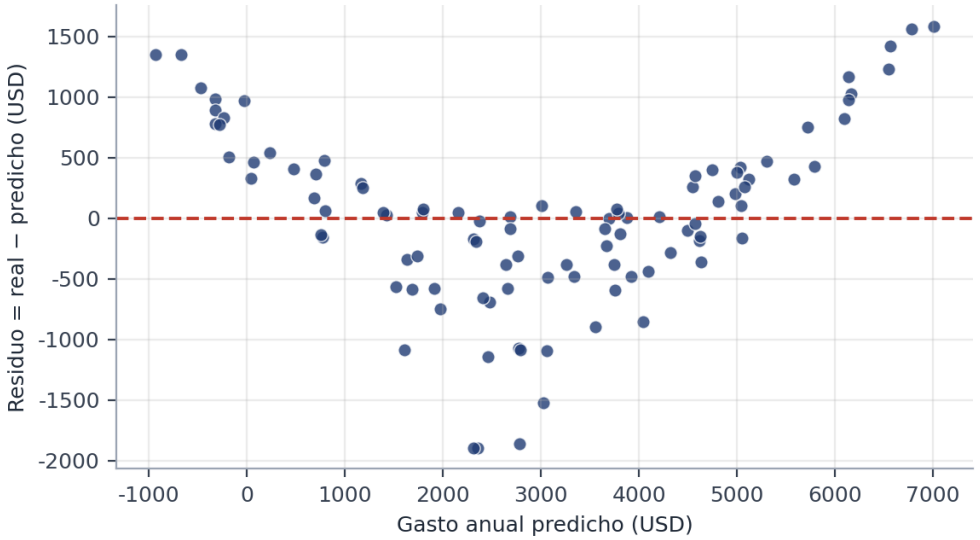
El modelo explica cerca del 88,95 % de la variabilidad del gasto anual en la prueba. El MAE equivale a cerca del 18,5 % del gasto anual medio (2.914,45 USD) y el RMSE a cerca del 24,6 %; como el RMSE es mayor que el MAE, algunos usuarios tienen errores considerablemente superiores al error típico. La Figura 8 muestra que las predicciones siguen la diagonal en los gastos medios, pero el modelo subestima los gastos más altos y predice valores negativos para 10 de los 100 usuarios de prueba (mínimo de −930,50 USD), algo imposible para un gasto anual. La Figura 9 presenta los residuos frente al valor predicho; el residuo medio es de +20,85 USD.

Figura 8
Gasto anual real frente a gasto anual predicho



Nota. Cada punto es un usuario del conjunto de prueba. La línea discontinua indica la predicción perfecta y el color, la magnitud del error absoluto.

Figura 9
Residuos de la regresión lineal frente al gasto predicho



Nota. Residuo = gasto real − gasto predicho.

Los coeficientes (Tabla 7) indican que, manteniendo constantes las demás variables, cada compra adicional en el último año se asocia con unos 131,86 USD más de gasto anual y cada dólar adicional de ticket promedio con unos 19,77 USD más. Los factores de inflación de la varianza de las seis variables numéricas están entre 1,01 y 1,02, por lo que no hay multicolinealidad relevante entre ellas.

Tabla 7
Coeficientes de la regresión lineal para gasto_anual

Variable (unidad)	Coeficiente (USD por unidad)	Sentido
Intercepto	-2632,30	—
edad (años)	1,42	Positivo
antiguedad_cuenta (meses)	-0,75	Negativo
compras_ult_anio (compras)	131,86	Positivo
ticket_promedio (USD)	19,77	Positivo
reclamos_abiertos (reclamos)	-41,30	Negativo
horas_app (horas/mes)	13,94	Positivo
nivel_Básico (indicadora)	29,36	Positivo
nivel_Medio (indicadora)	-27,87	Negativo
nivel_VIP (indicadora)	-1,49	Negativo

Nota. Modelo ajustado con las nueve columnas de entrada sin escalar, por lo que los coeficientes están en USD por unidad de cada variable. Los coeficientes de las indicadoras de `nivel_fidelidad` no deben leerse de forma aislada.

> **Hallazgo sobre la estructura del gasto**
> En el conjunto de datos, `gasto_anual` es prácticamente el producto de `compras_ult_anio` por `ticket_promedio` (correlación de 0,998). Un modelo lineal aditivo no puede representar un producto, lo que ayuda a explicar que subestime los gastos altos y produzca predicciones negativas en los bajos. Incorporar la interacción compras × ticket, o usar un modelo no lineal, es una mejora natural a evaluar. Además, si ambas variables están disponibles, el gasto anual es casi una consecuencia de ellas: su estimación sirve más para segmentar y controlar que como predicción anticipada.

Interpretación de resultados

Respuesta a la pregunta de clasificación

Con las variables disponibles, la capacidad de anticipar la fuga es limitada: los AUC están entre 0,54 y 0,70 y, con 4 casos positivos, sus diferencias no son concluyentes. La regresión logística tiene el AUC más alto, pero con su umbral de 0,50 detecta 2 de las 4 fugas a costa de 42 falsos positivos (precisión de 4,5 %). La SVM con umbral de 0,04 detecta también 2 de 4 con 13 falsos positivos, la mejor relación entre ambos errores en este experimento (F1 de 0,211 para la clase fuga). Random Forest detecta 1 de 4 con 23 falsos positivos y tiene la menor capacidad de ordenamiento. La respuesta a la pregunta es, por tanto, que la fuga puede anticiparse solo de forma parcial y que los modelos no deben usarse todavía como único criterio para campañas de retención.

Respuesta a la pregunta de regresión

El gasto anual sí puede estimarse con buena capacidad explicativa (R^2 de 0,8895 y un error medio cercano al 18,5 % del gasto medio), lo que sirve al área CRM para identificar segmentos de mayor valor y priorizar recursos. Los errores de la regresión se concentran en los gastos más altos (subestimación) y en los más bajos (predicciones negativas), por lo que el modelo es más confiable en la zona central de la distribución.

Valor para el negocio

Aunque la capacidad predictiva para la fuga es modesta, la regresión logística aporta una lectura útil para el área CRM: la frecuencia de compra es el factor asociado con menor fuga y los reclamos abiertos, el asociado con mayor fuga (Tabla 5). Vigilar la caída en las compras y resolver pronto los reclamos pueden servir como alertas tempranas mientras se mejora el modelo. Una línea de trabajo es combinar ambas salidas, cruzando la probabilidad de fuga con el gasto

estimado para priorizar a los usuarios de alto valor en riesgo; esa regla requeriría validación y costos de campaña definidos por el negocio.

Hallazgos por experimento

Tabla 8
Hallazgos principales de cada experimento

Experimento	Hallazgo
Regresión logística (run_log_reg_001)	Mayor AUC (0,703) y modelo interpretable; con umbral de 0,50 detecta la mitad de las fugas, pero con 42 falsas alarmas.
SVM (run_svm_rbf_002)	Mostró la paradoja de la exactitud: 96 % con recall 0 en el umbral de 0,50. Al fijar el umbral en 0,04 recuperó un recall de 0,50 con 13 falsos positivos (F1 de 0,211).
Random Forest (run_rand_forest_003)	Exactitud de 74 % con recall de 25 %: la exactitud resulta engañosa ante el desbalance. AUC de 0,540, cercano al azar.
Regresión lineal (run_lin_reg_004)	Ajuste alto (R^2 de 0,8895), con subestimación de los gastos altos y predicciones negativas en los bajos, asociadas a la estructura multiplicativa del gasto.

Nota. Los umbrales distintos y la cantidad de casos positivos impiden clasificar a los modelos por una única métrica.

Limitaciones

Primera, la prueba tiene solo 4 casos positivos: una sola observación cambia el recall en 25 puntos porcentuales y los AUC tienen un error de estimación amplio (cercano a 0,15). **Segunda**, los umbrales de 0,04 y 0,15 se ajustaron observando resultados sobre el conjunto de prueba, lo que puede dar una impresión optimista; lo adecuado es seleccionarlos con validación cruzada o un conjunto de validación y con costos de negocio definidos. **Tercera**, los hiperparámetros se usaron con valores por defecto, sin búsqueda sistemática. **Cuarta**, las comparaciones entre clasificadores solo son válidas para esta muestra y esta variable objetivo, y no se pueden extender a la regresión lineal. **Quinta**, la regresión lineal puede predecir gastos negativos y tiende a subestimar los gastos más altos. **Sexta**, se usó una única partición de entrenamiento y prueba, sin validación cruzada. **Séptima**, el conjunto de datos es académico y no representa los registros reales de Mercado Libre. **Octava**, los resultados de Random Forest dependen de la versión de la librería: una reejecución del mismo código en un entorno con scikit-

learn 1.8.0 dio un AUC de 0,5495 en lugar de 0,5404; por eso se documenta la versión utilizada (1.9.1).

Conclusiones

Se implementaron los cuatro modelos solicitados (regresión logística, SVM con kernel RBF y Random Forest para clasificar la fuga, y regresión lineal para estimar el gasto anual) sobre un conjunto de 500 usuarios de Mercado Libre, con siete variables de entrada originales que se convierten en nueve columnas tras la codificación. La preparación separó entrenamiento y prueba antes de ajustar el escalador, que se ajustó solo con los datos de entrenamiento, y la modalidad consolidada permitió evaluar los tres clasificadores sobre las mismas 100 observaciones de prueba.

En clasificación, los AUC fueron 0,703 para la regresión logística, 0,620 para la SVM y 0,540 para Random Forest. Dado el desbalance (96,4 % frente a 3,6 %) y los 4 casos positivos de la prueba, el error estándar aproximado del AUC es de 0,15 y las diferencias entre modelos no son concluyentes; la capacidad de detectar la fuga con estas variables es todavía débil, ya que ningún modelo identificó más de 2 de las 4 fugas.

Los experimentos ilustran los efectos del desbalance y del umbral. La SVM alcanzó 96 % de exactitud con recall 0 en el umbral de 0,50; al bajarlo a 0,04 detectó la mitad de las fugas con 13 falsos positivos (F1 de 0,211). Random Forest obtuvo 74 % de exactitud con un recall de 0,25, y la regresión logística, con su umbral de 0,50, detectó la mitad de las fugas a costa de 42 falsas alarmas. La exactitud, por sí sola, resulta engañosa; la elección del modelo y del umbral debe responder al costo relativo de perder a un cliente frente al de contactar a uno que no se iba a ir.

Desde la perspectiva del negocio, la regresión logística mostró que la frecuencia de compra es el principal factor asociado con menor fuga (OR de 0,515 por desviación estándar) y los reclamos abiertos, el principal factor asociado con mayor fuga (OR de 1,152). Los datos descriptivos respaldan esa lectura: los usuarios con fuga compraron menos, tuvieron un ticket

menor y más reclamos abiertos. Se trata de asociaciones y no de relaciones causales, y con 18 casos de fuga pueden ser inestables.

En regresión, el modelo alcanzó un MAE de 538,87 USD, un RMSE de 716,21 USD y un R^2 de 0,8895, un ajuste alto (error medio cercano al 18,5 % del gasto medio) que permite estimar el gasto anual y segmentar usuarios por valor. Sin embargo, subestima los gastos más altos y predice valores negativos para 10 de 100 usuarios, y el análisis de los datos muestra que el gasto es casi el producto de las compras por el ticket promedio, una relación que un modelo lineal aditivo no captura.

En conjunto, los modelos deben considerarse un punto de partida experimental: sirven para explorar qué variables se asocian con la fuga y con el gasto, pero no están listos para decidir por sí solos campañas de retención. Los resultados dependen además de la versión de las librerías, por lo que registrar las ejecuciones en MLflow y documentar el entorno es parte de la trazabilidad del trabajo.

Recomendaciones y trabajo futuro

(1) Aplicar técnicas de remuestreo, como SMOTE, solo sobre el conjunto de entrenamiento, y comparar con el ajuste de pesos de clase. (2) Usar validación cruzada estratificada y un conjunto de validación para ajustar hiperparámetros y seleccionar el umbral, reservando la prueba para la evaluación final. (3) Definir el umbral con base en el costo comercial de perder un cliente frente al de contactar a uno que no se iba a ir, y reportar también la curva precisión–recall, más informativa con clases desbalanceadas. (4) Evaluar la calibración de las probabilidades antes de comparar umbrales entre algoritmos. (5) Para el gasto anual, incorporar la interacción compras × ticket o probar modelos no lineales, y restringir las predicciones a valores no negativos. (6) Ampliar la muestra, en particular el número de casos de fuga, antes de usar los coeficientes para tomar decisiones comerciales.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Corporación Unificada Nacional de Educación Superior. (s. f.-a). *ACA No. 1 (30 %): Machine Learning* [Guía de actividad]. CUN.

Corporación Unificada Nacional de Educación Superior. (s. f.-b). *dataset_mercadolibre_aca1.xlsx* [Conjunto de datos]. Material de la asignatura Machine Learning, CUN.

Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine Learning, 20*(3), 273–297. https://doi.org/10.1007/BF00994018

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters, 27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

Hanley, J. A., y McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, *143*(1), 29–36. https://doi.org/10.1148/radiology.143.1.7063747

Hosmer, D. W., Lemeshow, S., y Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley. https://doi.org/10.1002/9781118548387

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Zaharia, M., Chen, A., Davidson, A., Ghodsi, A., Hong, S. A., Konwinski, A., Murching, S., Nykodym, T., Ogilvie, P., Parkhe, M., Xie, F., y Zumar, C. (2018). Accelerating the machine learning lifecycle with MLflow. *IEEE Data Engineering Bulletin, 41*(4), 39–45.

Anexo A. Evidencias de ejecución

Este anexo reúne las capturas de pantalla de la ejecución de cada modelo, identificadas por modelo y experimento (ejecución de MLflow). Las capturas muestran la salida de los cuadernos adaptados y de MLflow; no se adjuntan los cuadernos ni archivos .ipynb. La Tabla A1 indica a qué experimento corresponde cada figura.

Tabla A1
Índice de evidencias de ejecución

Figura	Modelo	Experimento / ejecución	Contenido de la captura
A1	Todos	Carga de datos	Dimensiones (500, 11) y primeras filas
A2	Todos	Exploración de datos	Estadísticas descriptivas con describe()
A3	Regresión logística	run_log_reg_001	Matriz de confusión (umbral 0,50)
A4	Regresión logística	run_log_reg_001	Reporte de clasificación (informe_clasificacion.csv)
A5	Regresión logística	run_log_reg_001	Curva ROC (AUC = 0,703)
A6	SVM	run_svm_rbf_002	Salida de ejecución con umbral 0,04
A7	SVM	run_svm_rbf_002	Matriz de confusión (umbral 0,04)
A8	SVM	run_svm_rbf_002	Reporte de clasificación (informe_clasificacion.csv)
A9	SVM	run_svm_rbf_002	Curva ROC (AUC = 0,620)
A10	Random Forest	run_rand_forest_003	Matriz de confusión (umbral 0,15)
A11	Random Forest	run_rand_forest_003	Reporte de clasificación (informe_clasificacion.csv)
A12	Random Forest	run_rand_forest_003	Curva ROC (AUC = 0,540)
A13	Random Forest	run_rand_forest_003	Árbol de decisión n.º 0 del ensamble
A14	Random Forest	run_rand_forest_003	Árbol de decisión n.º 1 del ensamble
A15	Random Forest	run_rand_forest_003	Árbol de decisión n.º 2 del ensamble
A16	Random Forest	run_rand_forest_003	Árbol de decisión n.º 3 del ensamble
A17	Random Forest	run_rand_forest_003	Árbol de decisión n.º 4 del ensamble
A18	Random Forest	run_rand_forest_003	Fragmento del código del cuaderno
A19	Regresión lineal	run_lin_reg_004	Gasto real frente a estimado
A20	Regresión lineal	run_lin_reg_004	Métricas (metricas_regresion.csv)
A21	Regresión lineal	run_lin_reg_004	Vista general de la ejecución en MLflow
A22	Regresión lineal	run_lin_reg_004	Gráficos de las métricas en MLflow
A23	Los tres clasificadores	run_log_reg_001, run_svm_rbf_002, run_rand_forest_003	Detalle de las ejecuciones

Figura	Modelo	Experimento / ejecución	Contenido de la captura
A24	Los tres clasificadores	run_log_reg_001, run_svm_rbf_002, run_rand_forest_003	Parámetros registrados
A25	Los tres clasificadores	run_log_reg_001, run_svm_rbf_002, run_rand_forest_003	Métricas registradas
A26	Los tres clasificadores	run_log_reg_001, run_svm_rbf_002, run_rand_forest_003	Gráfico de coordenadas paralelas
A27	Los tres clasificadores	run_log_reg_001, run_svm_rbf_002, run_rand_forest_003	Tabla comparativa de métricas
A28	Los tres clasificadores	run_log_reg_001, run_svm_rbf_002, run_rand_forest_003	Curvas ROC comparativas (original)

Nota. Las evidencias se organizan por modelo y experimento para facilitar su consulta.

A.1. Carga y exploración de los datos

Figura A1

Carga del archivo y primeras filas del conjunto de datos

Dimensiones: (500, 11)

	edad	antiguedad_cuenta	compras_ult_anio	ticket_promedio	reclamos_abiertos	horas_app	fuga	gasto_anual	nivel_Básico	nivel_Medio	nivel_VIP
0	56	16	35	163.991340	1	3.789610	0	5774.040419	0	0	1
1	69	61	23	141.896564	0	15.717926	0	3562.247330	0	1	0
2	46	64	14	198.263668	1	8.393984	0	2874.834355	1	0	0
3	32	63	28	40.140450	1	25.146667	0	1519.055284	1	0	0
4	60	69	7	193.841557	3	0.933455	0	1334.344910	1	0	0

Nota. Dimensiones del conjunto: (500, 11).

Figura A2

Estadísticas descriptivas del conjunto de datos

	count	mean	std	min	25%	50%	75%	max
edad	500.0	44.220000	15.036082	18.000000	32.000000	45.000000	57.000000	69.000000
antiguedad_cuenta	500.0	35.052000	20.719747	1.000000	17.000000	34.000000	53.000000	71.000000
compras_ult_anio	500.0	20.408000	11.620827	0.000000	10.000000	22.000000	30.250000	39.000000
ticket_promedio	500.0	133.443724	68.274564	16.160896	71.616152	136.820644	188.257889	249.862226
reclamos_abiertos	500.0	1.008000	0.958004	0.000000	0.000000	1.000000	2.000000	4.000000
horas_app	500.0	15.226898	8.661867	0.500343	7.903742	15.242614	22.596185	29.847169
fuga	500.0	0.036000	0.186477	0.000000	0.000000	0.000000	0.000000	1.000000
gasto_anual	500.0	2914.452870	2158.288506	10.000000	1160.623158	2285.372327	4224.283354	9265.228866
nivel_Básico	500.0	0.504000	0.500485	0.000000	0.000000	1.000000	1.000000	1.000000
nivel_Medio	500.0	0.304000	0.460443	0.000000	0.000000	0.000000	1.000000	1.000000
nivel_VIP	500.0	0.192000	0.394268	0.000000	0.000000	0.000000	0.000000	1.000000

Nota. Las 11 columnas tienen 500 valores no nulos.

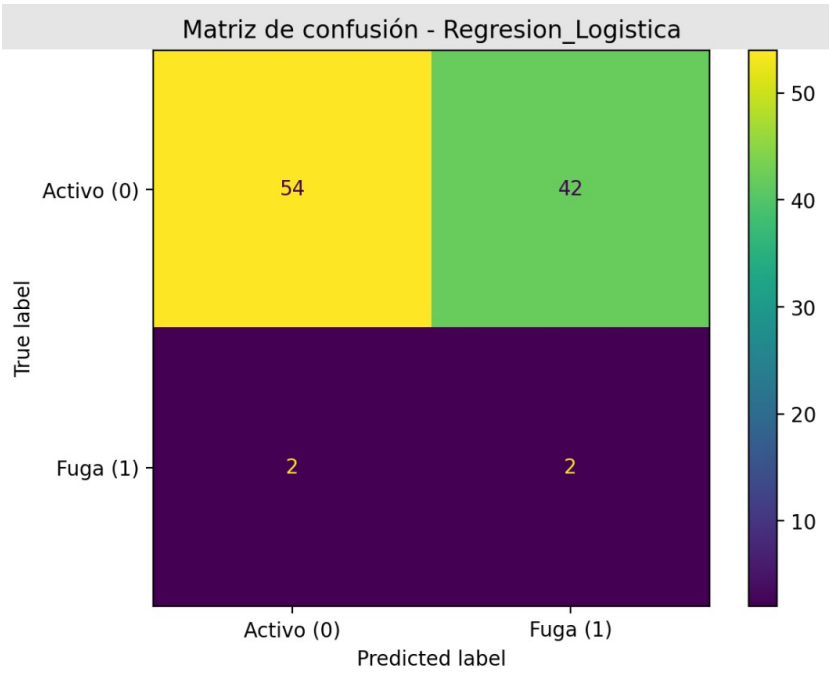
EVIDENCIA DEL CUADERNO · CARGA Y ESTRUCTURA

```
import pandas as pd
df = pd.read_excel("dataset_mercadolibre_aca1.xlsx")
print(df.shape)  # (500, 11)
print(df.columns.tolist())
Columnas: edad, antiguedad_cuenta, compras_ult_anio, ticket_promedio, horas_app,
reclamos_abiertos, nivel_Básico, nivel_Medio, nivel_VIP, fuga, gasto_anual
```

A.2. Regresión logística (run_log_reg_001)

Figura A3

Matriz de confusión de la regresión logística



Nota. VN = 54, FP = 42, FN = 2, VP = 2.

Figura A4

Reporte de clasificación de la regresión logística en MLflow

evidencias/informe_clasificacion.csv 316B

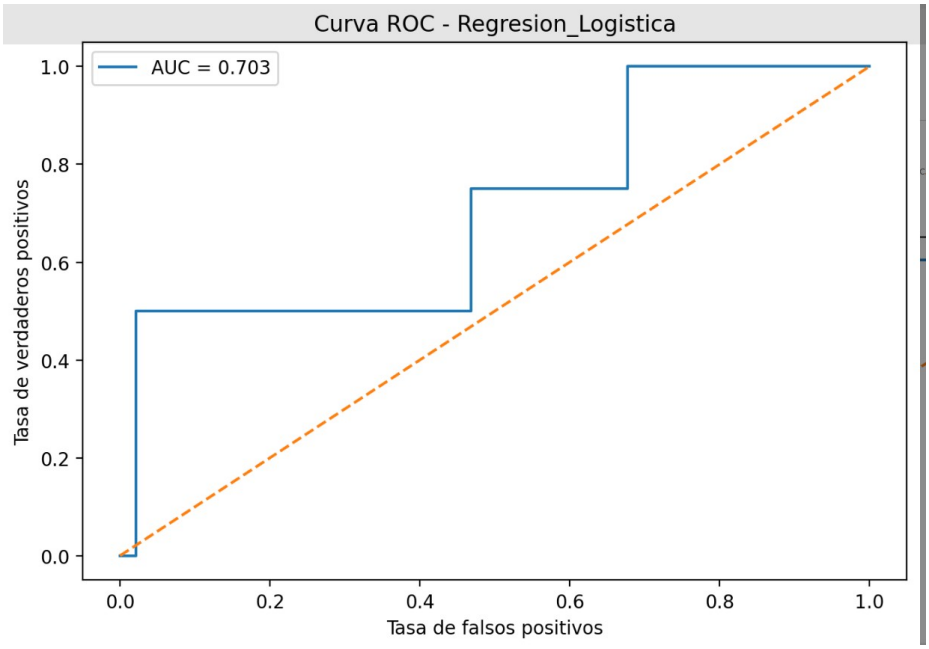
Path: file:c:/Users/julip/OneDrive/Documentos/mlruns/2/f37c67cf2f9c4d4182427060a1fb11eb/artifacts/evidencias/informe_clasificacion.csv

Previewing the first 5 rows

	precision	recall	f1-score	support
	0.9642857142857143	0.5625	0.7105263157894737	96
	0.045454545454545456	0.5	0.08333333333333333	4
	0.56	0.56	0.56	0.56
	0.5048701298701299	0.53125	0.3969298245614035	100
	0.9275324675324675	0.56	0.6854385964912281	100

Nota. Vista previa del artefacto `evidencias/informe_clasificacion.csv` de la ejecución.

Figura A5
Curva ROC de la regresión logística



Nota. AUC = 0,703. Clase positiva: fuga = 1.

EVIDENCIA DEL CUADERNO · REGRESIÓN LOGÍSTICA

```
y = df["fuga"];  X = df.drop(columns=["fuga", "gasto_anual"])
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)  # ajuste solo en train
X_test_scaled = scaler.transform(X_test)
modelo = LogisticRegression(class_weight="balanced", max_iter=1000, random_state=42)
modelo.fit(X_train_scaled, y_train)
Salida documentada: matriz [[54, 42], [2, 2]] · ROC-AUC = 0.7031
```

A.3. SVM con kernel RBF (run_svm_rbf_002)

Figura A6

Salida de ejecución del modelo SVM con umbral de 0,04

```
        EVALUACIÓN DEL MODELO SVM - UMBRAL: 0.04
============================================================

Matriz de Confusión Ajustada:
[[83 13]
 [ 2  2]]

Reporte de Clasificación Ajustado:
              precision    recall  f1-score   support

           0       0.98      0.86      0.92        96
           1       0.13      0.50      0.21         4

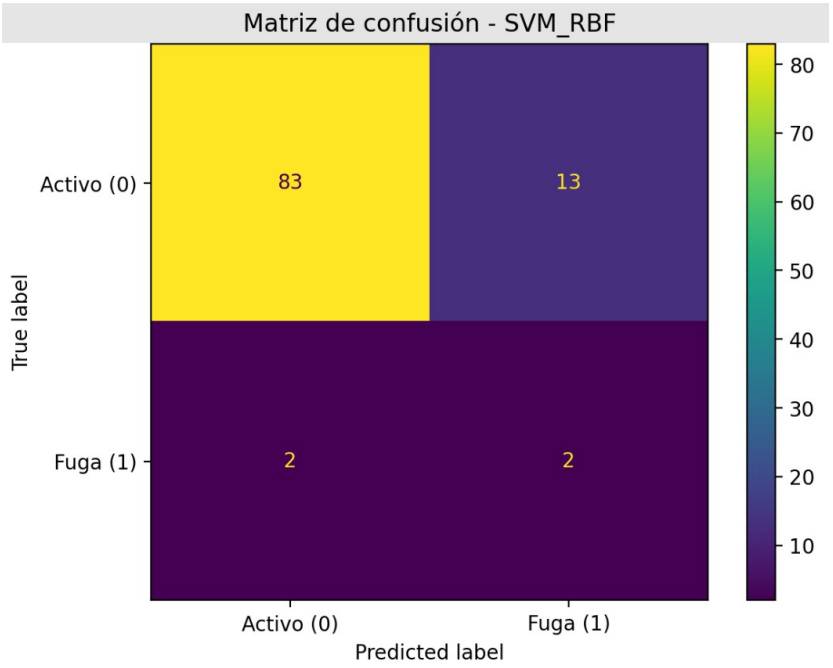
    accuracy                           0.85       100
   macro avg       0.55      0.68      0.56       100
weighted avg       0.94      0.85      0.89       100

Área Bajo la Curva ROC (ROC-AUC): 0.6198
------------------------------------------------------------
```

Nota. Matriz de confusión ajustada, reporte de clasificación y ROC-AUC (0,6198).

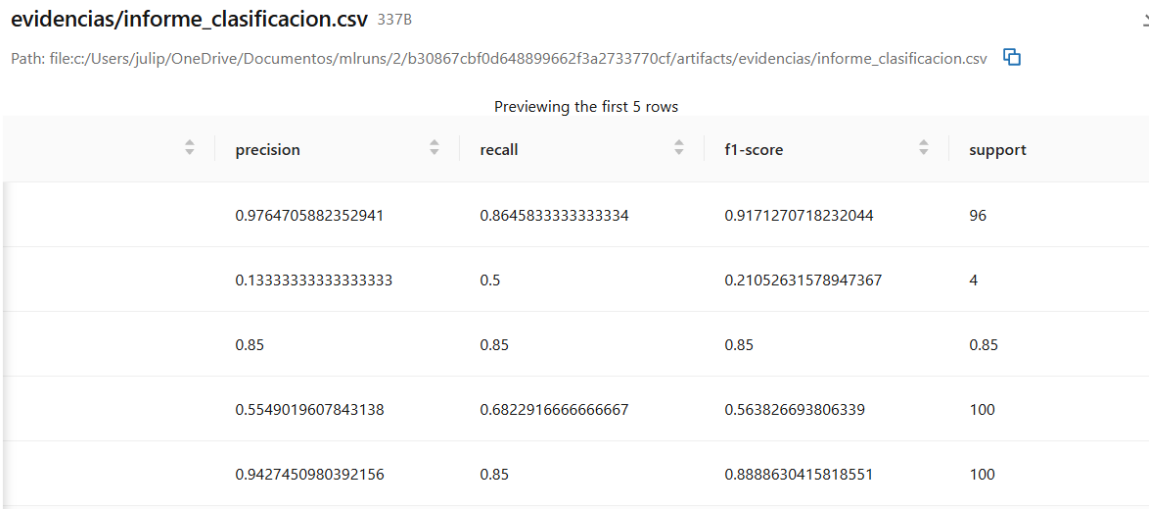
Figura A7

Matriz de confusión de la SVM



Nota. VN = 83, FP = 13, FN = 2, VP = 2.

Figura A8
Reporte de clasificación de la SVM en MLflow



evidencias/informe_clasificacion.csv 337B

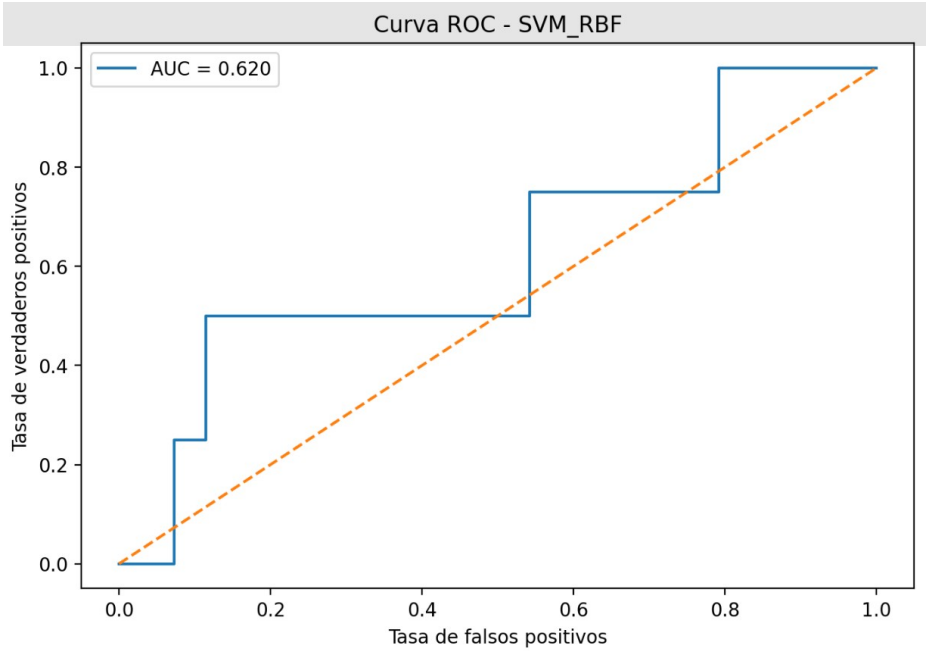
Path: file:c:/Users/julip/OneDrive/Documentos/mlruns/2/b30867cbf0d648899662f3a2733770cf/artifacts/evidencias/informe_clasificacion.csv

Previewing the first 5 rows

	precision	recall	f1-score	support
	0.9764705882352941	0.8645833333333334	0.9171270718232044	96
	0.13333333333333333	0.5	0.21052631578947367	4
	0.85	0.85	0.85	0.85
	0.5549019607843138	0.6822916666666667	0.563826693806339	100
	0.9427450980392156	0.85	0.8888630415818551	100

Nota. Vista previa del artefacto `evidencias/informe_clasificacion.csv` de la ejecución.

Figura A9
Curva ROC de la SVM



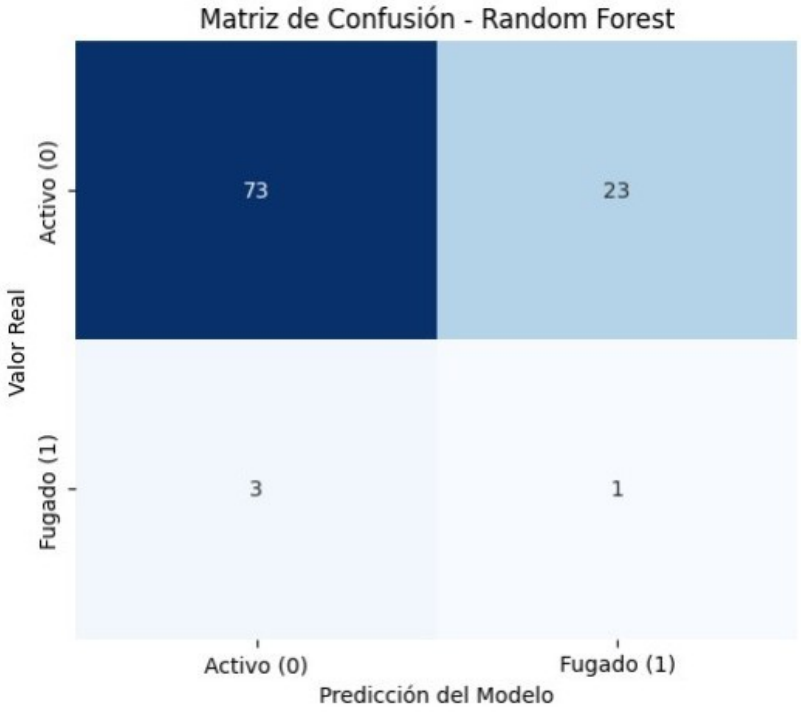
Nota. AUC = 0,620. Clase positiva: fuga = 1.

EVIDENCIA DEL CÓDIGO · SVM (JSON DEL CUADERNO)

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20,
    random_state=42, stratify=y)
scaler = StandardScaler(); X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
svm_model = SVC(kernel="rbf", C=1.0, probability=True, random_state=42)
svm_model.fit(X_train_scaled, y_train); y_probs = svm_model.predict_proba(X_test_scaled)[:, 1]
umbral = 0.04; y_pred_ajustado = (y_probs >= umbral).astype(int)
Salida documentada: matriz [[83, 13], [2, 2]] · ROC-AUC = 0.6198
```

A.4. Random Forest (run_rand_forest_003)

Figura A10
Matriz de confusión del Random Forest



Nota. VN = 73, FP = 23, FN = 3, VP = 1.

Figura A11
Reporte de clasificación del Random Forest en MLflow

evidencias/informe_clasificacion.csv 341B

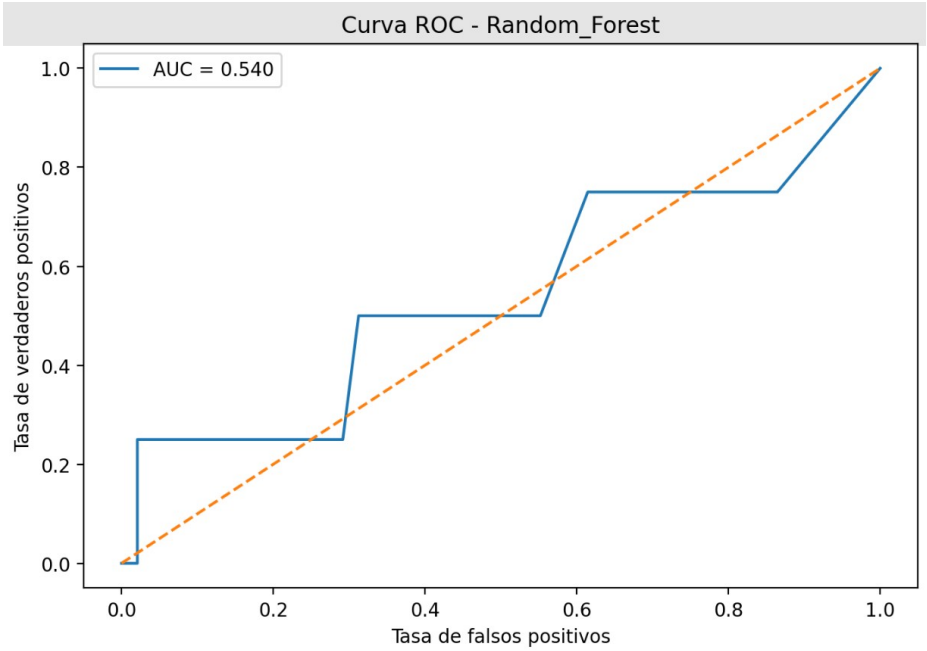
Path: file:c:/Users/julip/OneDrive/Documentos/mlruns/2/de918dd2624c4665864c25bca3131270/artifacts/evidencias/informe_clasificacion.csv

Previewing the first 5 rows

	precision	recall	f1-score	support
	0.9605263157894737	0.7604166666666666	0.8488372093023255	96
	0.041666666666666664	0.25	0.07142857142857142	4
	0.74	0.74	0.74	0.74
	0.5010964912280702	0.5052083333333333	0.46013289036544847	100
	0.9237719298245615	0.74	0.8177408637873755	100

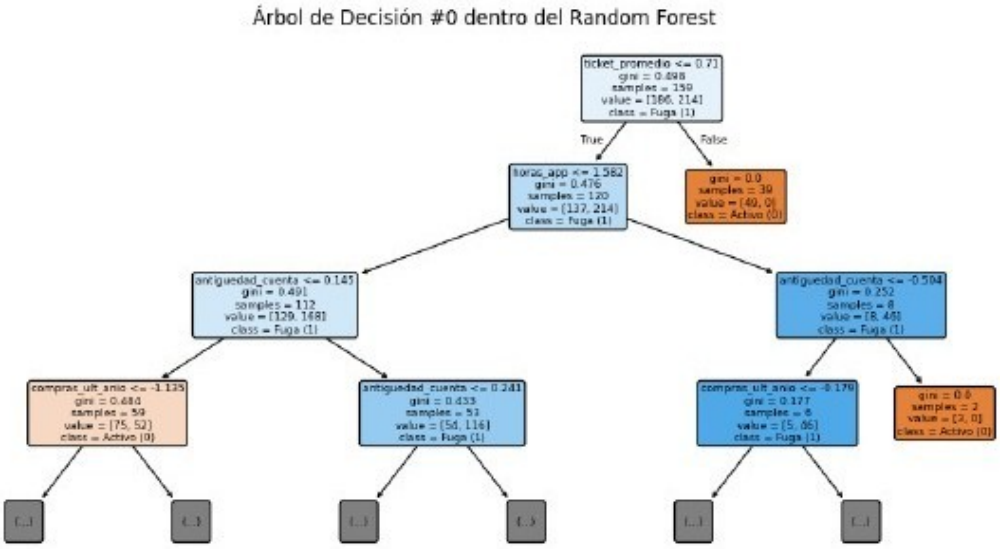
Nota. Vista previa del artefacto `evidencias/informe_clasificacion.csv` de la ejecución.

Figura A12
Curva ROC del Random Forest



Nota. AUC = 0,540 (0,5404 con más decimales). Clase positiva: fuga = 1.

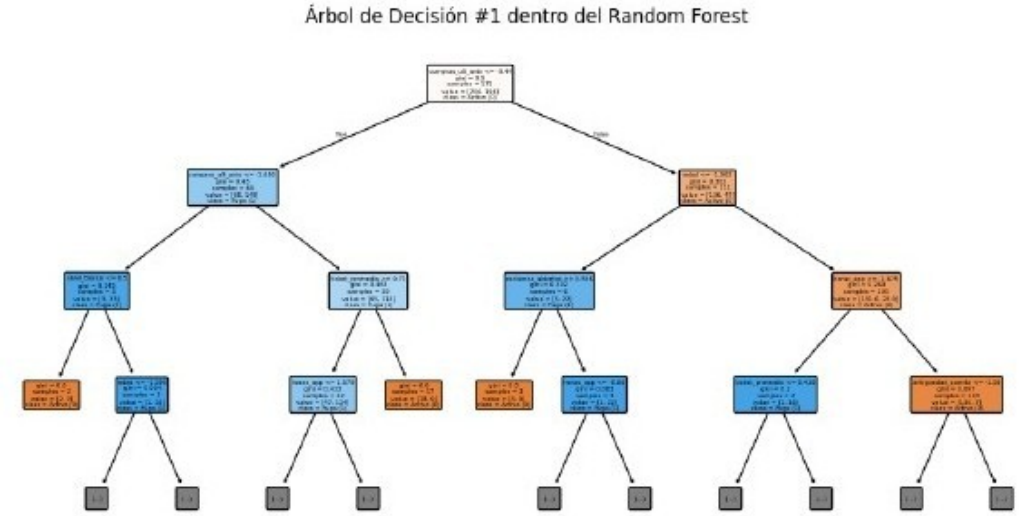
Figura A13
Árbol de decisión n.º 0 dentro del Random Forest



Nota. Visualización con `plot_tree` y `max_depth = 3`; los nodos grises indican ramas no mostradas.

Figura A14

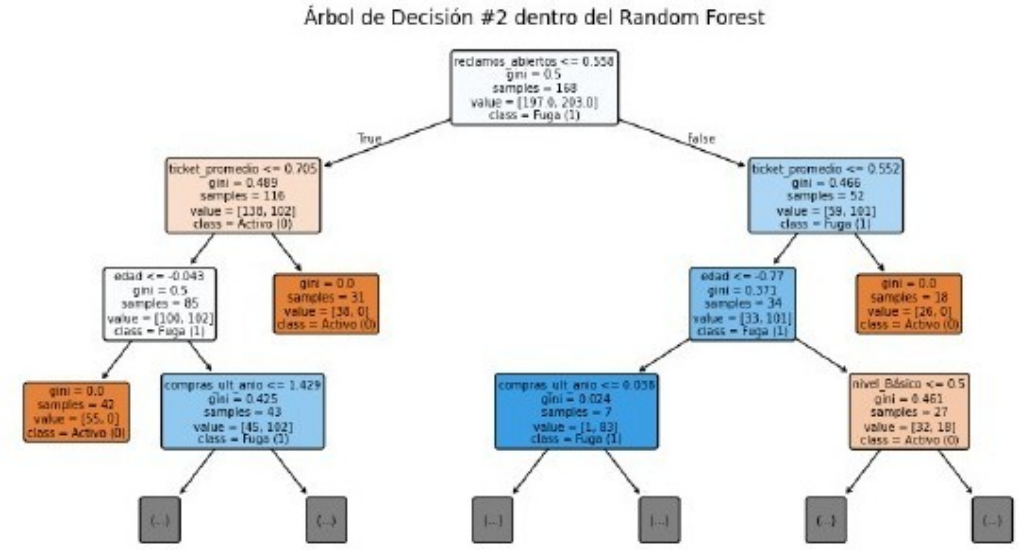
Árbol de decisión n.º 1 dentro del Random Forest



Nota. Visualización con `plot_tree` y `max_depth = 3`; los nodos grises indican ramas no mostradas.

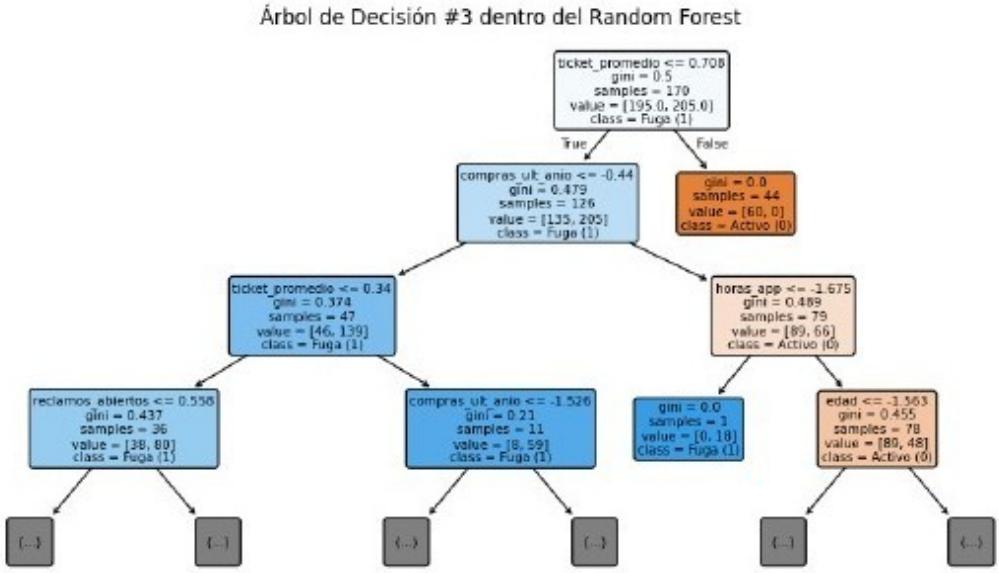
Figura A15

Árbol de decisión n.º 2 dentro del Random Forest



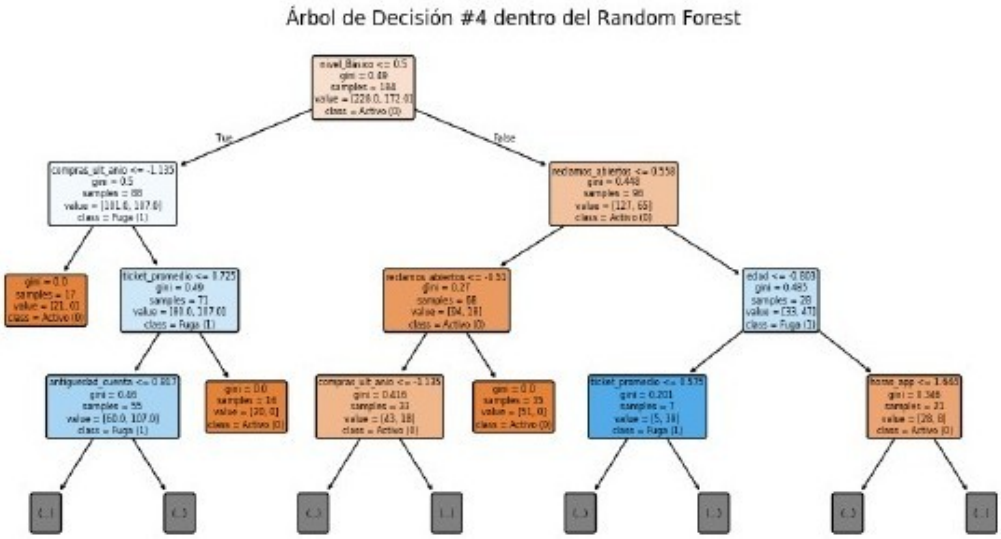
Nota. Visualización con `plot_tree` y `max_depth = 3`; los nodos grises indican ramas no mostradas.

Figura A16
Árbol de decisión n.º 3 dentro del Random Forest



Nota. Visualización con `plot_tree` y `max_depth = 3`; los nodos grises indican ramas no mostradas.

Figura A17
Árbol de decisión n.º 4 dentro del Random Forest



Nota. Visualización con `plot_tree` y `max_depth = 3`; los nodos grises indican ramas no mostradas.

Figura A18
Fragmento del código del cuaderno del Random Forest

```
# FASE 2: PREPARACIÓN E IMPLEMENTACIÓN - RANDOM FOREST (MERCADO LIBRE)
# [...] importaciones omitidas
df = pd.read_excel(r"...\dataset_mercadolibre_aca1.xlsx")   # ruta local omitida
```

```
# 2. Características y variable objetivo (clasificación: fuga)
features = [
    'edad', 'antiguedad_cuenta', 'compras_ult_anio', 'ticket_promedio',
    'reclamos_abiertos', 'horas_app', 'nivel_Básico', 'nivel_Medio', 'nivel_VIP'
]
X = df[features]
y = df['fuga']

# 3. Separación train-test (80/20) ANTES de transformar
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# 4. Escalamiento de variables continuas (fit solo con entrenamiento)
scaler = StandardScaler()
cols_a_escalar = ['edad', 'antiguedad_cuenta', 'compras_ult_anio',
                  'ticket_promedio', 'reclamos_abiertos', 'horas_app']
X_train_scaled = X_train.copy()
X_test_scaled = X_test.copy()
X_train_scaled[cols_a_escalar] = scaler.fit_transform(X_train[cols_a_escalar])
X_test_scaled[cols_a_escalar] = scaler.transform(X_test[cols_a_escalar])

# 5. Entrenamiento: Random Forest manejando el desbalance de clases
rf_model = RandomForestClassifier(n_estimators=100, class_weight='balanced', random_state=42)
rf_model.fit(X_train_scaled, y_train)

# Predicciones y probabilidades con umbral ajustado
y_prob = rf_model.predict_proba(X_test_scaled)[:, 1]
umbral = 0.15
y_pred = (y_prob >= umbral).astype(int)

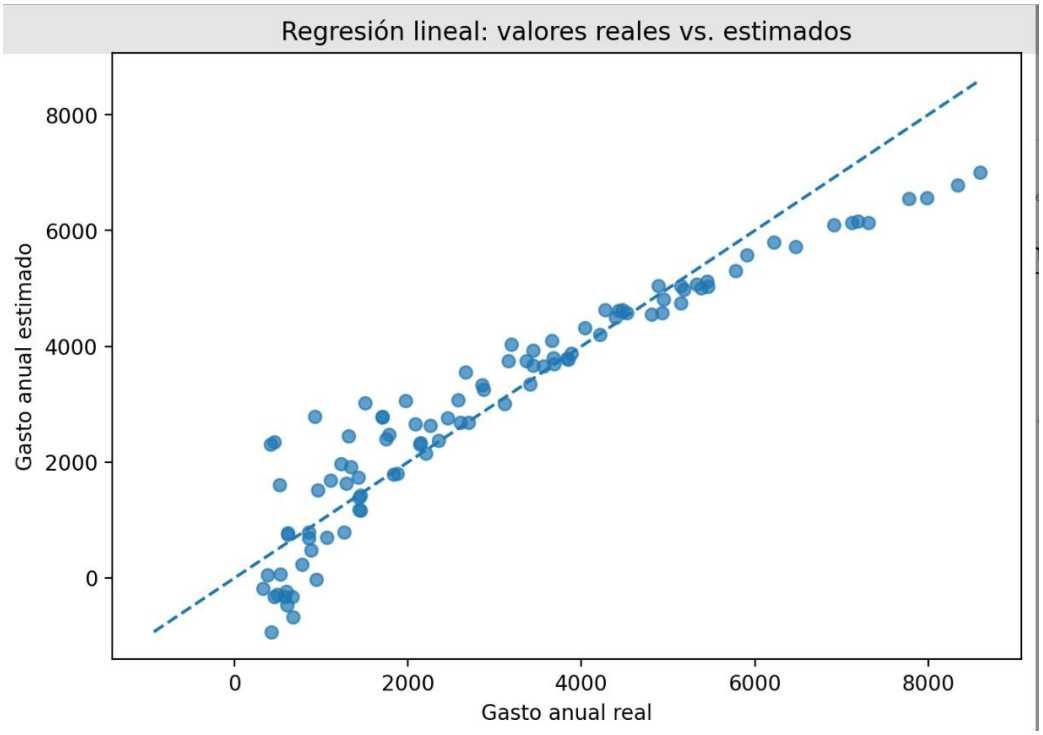
# 6. Evaluación (exactitud, recall, F1, ROC-AUC, reporte, matriz y curva ROC)
# [...] código de métricas y gráficas omitido
```

Nota. Se omitieron las importaciones, la ruta local del archivo y el código de las métricas y gráficas. La configuración coincide con la registrada en MLflow.

A.5. Regresión lineal (run_lin_reg_004)

Figura A19

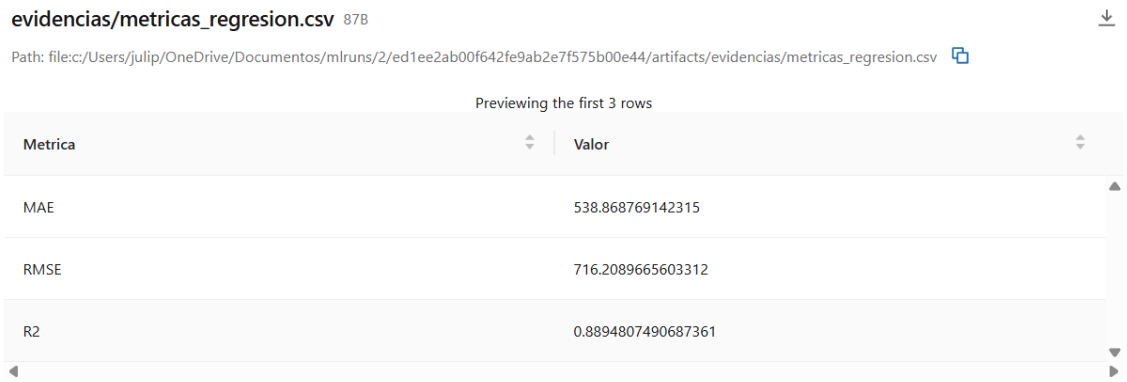
Valores reales frente a valores estimados de la regresión lineal



Nota. Cada punto es un registro del conjunto de prueba.

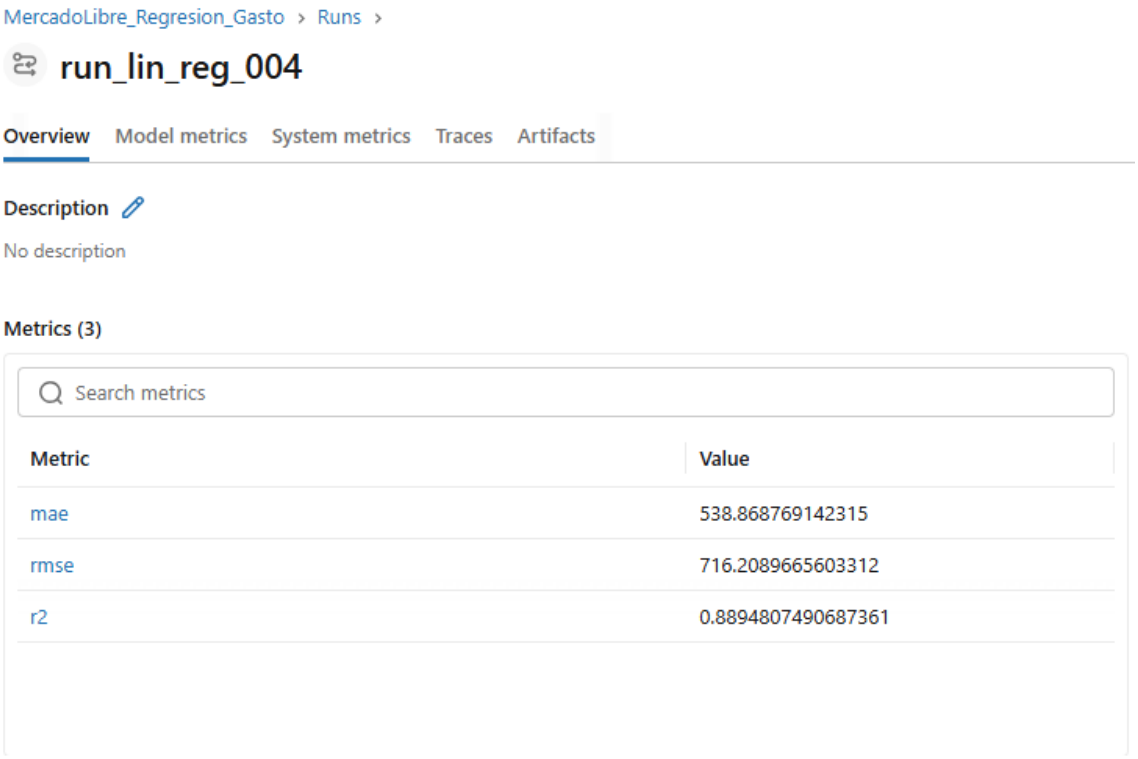
Figura A20

Métricas de la regresión lineal en MLflow



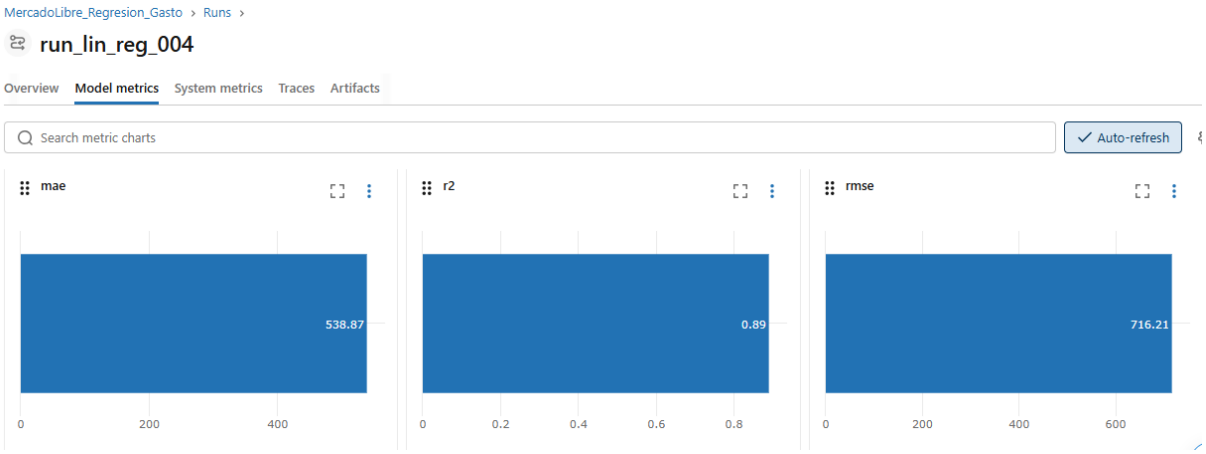
Nota. MAE = 538,87; RMSE = 716,21; R^2 = 0,8895.

Figura A21
Métricas de la regresión lineal en la vista general de MLflow



Nota. Experimento MercadoLibre_Regresion_Gasto.

Figura A22
Gráficos de las métricas de la regresión lineal en MLflow

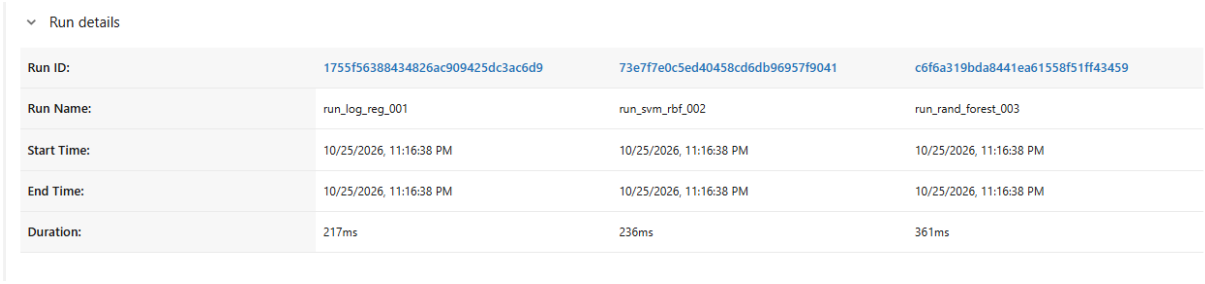


EVIDENCIA DEL CUADERNO · REGRESIÓN LINEAL

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, random_state=42)
modelo = Pipeline([("imputador", SimpleImputer(strategy="median")),
                   ("regresion_lineal", LinearRegression())])
modelo.fit(X_train, y_train); y_pred = modelo.predict(X_test)
MAE = mean_absolute_error(y_test, y_pred)       · 538.8688
RMSE = sqrt(mean_squared_error(y_test, y_pred)) · 716.2090
R² = r2_score(y_test, y_pred)                   · 0.8895
```

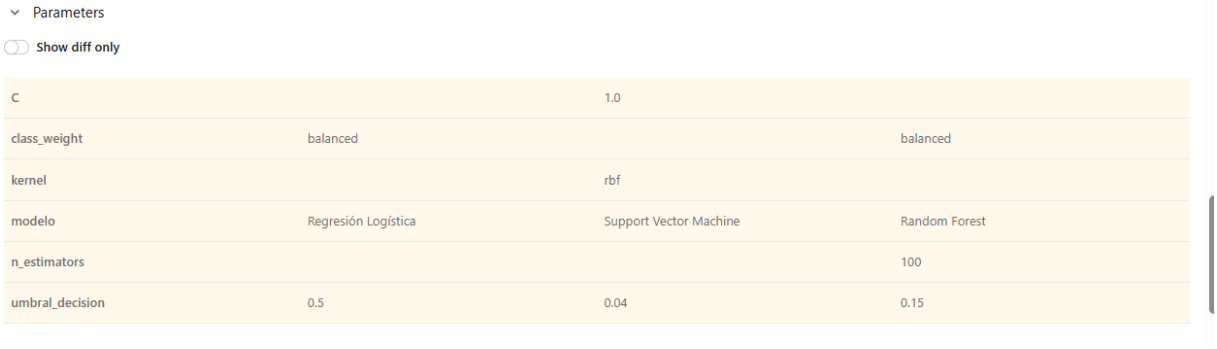
A.6. Comparación de los clasificadores en MLflow

Figura A23
Detalle de las ejecuciones de clasificación en MLflow



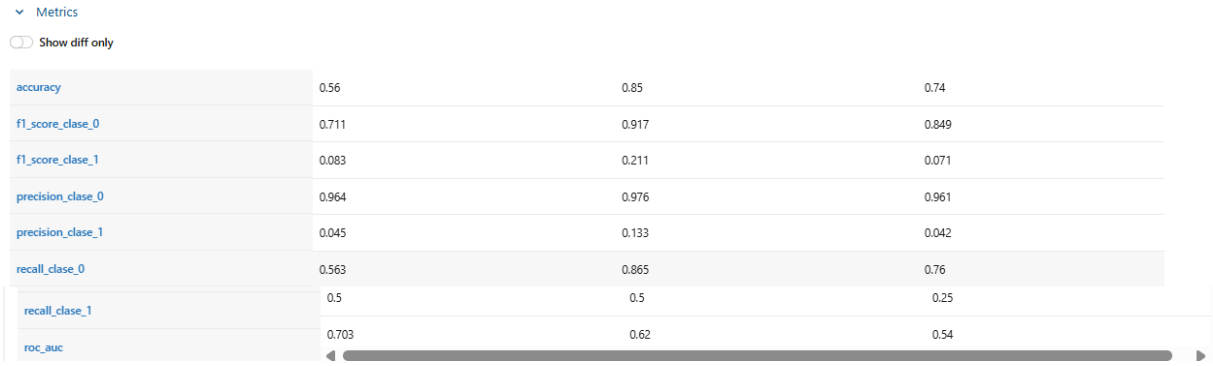
Nota. Columnas: run_log_reg_001, run_svm_rbf_002 y run_rand_forest_003.

Figura A24
Parámetros registrados en MLflow



Nota. El modelo se identifica en la fila `modelo`; el umbral de decisión se registró como `umbral_decision`.

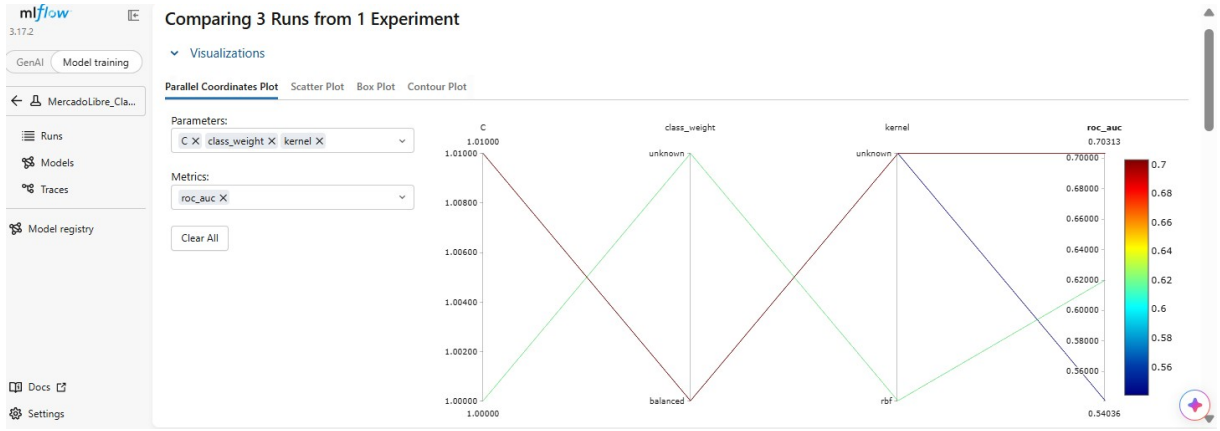
Figura A25
Métricas registradas en MLflow



Nota. Columnas en el mismo orden de la Figura A23.

Figura A26

Comparación de las ejecuciones de clasificación en MLflow



Nota. Gráfico de coordenadas paralelas con los parámetros `C`, `class_weight` y `kernel` y la métrica `roc_auc`.

Figura A27

Tabla comparativa de los clasificadores

1. Tabla comparativa de los clasificadores

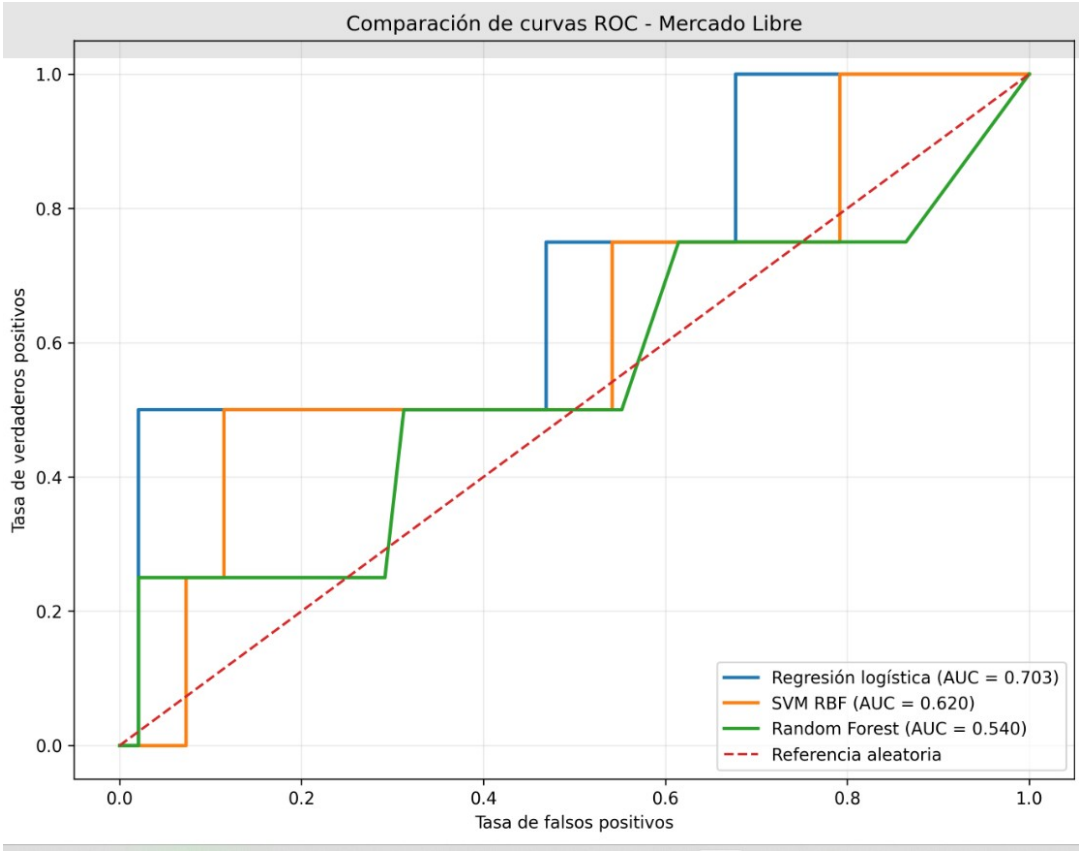
Valores redondeados a cuatro decimales. La clase 1 representa a los clientes que abandonan.

Métrica	Regresión logística	SVM RBF	Random Forest
AUC-ROC	**0,7031**	0,6198	0,5404
Exactitud (*accuracy*)	0,5600	**0,8500**	0,7400
Precisión de fuga	0,0455	**0,1333**	0,0417
Recall de fuga	0,5000	0,5000	0,2500
F1-score de fuga	0,0833	**0,2105**	0,0714
Umbral de decisión	0,50	0,04	0,15

Nota. Valores redondeados a cuatro decimales; la clase 1 representa a los usuarios con fuga.

Figura A28

Comparación de las curvas ROC de los tres clasificadores



Nota. Curvas calculadas sobre las mismas 100 observaciones de prueba.